

Μηχανική Μάθηση

1η σειρά ασκήσεων

Νασοπούλου Ελένη – 03121087

Ονοματεπώνυμο: Νασοπούλου Ελένη

AM: 03121087

Email address: eleni.nspl@gmail.com

Οι κώδικες των προγραμμάτων βρίσκονται στο [τέλος](#) της εργασίας.

Άσκηση 1.1 (Least squares estimation)

Θεωρούμε το παρακάτω γραμμικό μοντέλο γέννησης δεδομένων:

$$y_i = x_i^T w + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2), \quad i = 1, 2, \dots, N$$

Όπου $x_i = [1, x_{i1}, \dots, x_{ip}]^T$ και $w = [w_0, w_1, \dots, w_p]^T$ άγνωστο διάνυσμα παραμέτρων. Έστω επίσης X ο $N \times (p + 1)$ πίνακας με $N > p$, του οποίου γραμμές είναι τα $x_i^T, i = 1, 2, \dots, N$ και για τον οποίο υποθέτουμε ότι $\text{rank}(X) = p + 1$.

Ερώτημα α

Με βάση το παραπάνω μοντέλο, το $N \times 1$ διάνυσμα $y = [y_0, y_1, \dots, y_N]^T$. Το τυχαίο διάνυσμα y ακολουθεί κανονική κατανομή.

Μέση τιμή y :

$$\begin{aligned} E[y] &= & // y &= Xw + \varepsilon \\ E[Xw + \varepsilon] &= & // \text{γραμμικότητα μέσης τιμής} \\ E[Xw] + E[\varepsilon] &= & // \varepsilon \sim \mathcal{N}(0, \sigma^2 I) \Rightarrow E[\varepsilon] = 0 \\ E[Xw] &= & // Xw \text{ σταθερά} \\ Xw \end{aligned}$$

Συνεπώς, η μέση τιμή του y είναι $E[y] = Xw$.

Διακύμανση y :

$$\begin{aligned} \text{Cov}[y] &= & // y &= Xw + \varepsilon \\ \text{Cov}[Xw + \varepsilon] &= & // Xw \text{ σταθερά} \\ \text{Cov}[\varepsilon] &= & // \varepsilon \sim \mathcal{N}(0, \sigma^2 I) \Rightarrow \text{Cov}[\varepsilon] = \sigma^2 I \\ \sigma^2 I \end{aligned}$$

Συνεπώς, η διακύμανση του y είναι $\text{Cov}[y] = \sigma^2 I$.

Επομένως, το διάνυσμα εξόδου y ακολουθεί κατανομή: $y \sim \mathcal{N}(Xw, \sigma^2 I)$ και έχει την ακόλουθη συνάρτηση πυκνότητας πιθανότητας:

$$p(y) = \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left(-\frac{1}{2\sigma^2} (y - Xw)^T (y - Xw)\right)$$

Ερώτημα β

Θεωρούμε τα $x_i, y_i, i = 1, 2, \dots, N$ ως δεδομένα εκπαίδευσης. Προκειμένου να βρούμε τον εκτιμητή ελαχίστων τετραγώνων $\hat{w}$ του w θα ελαχιστοποιήσουμε την συνάρτηση κόστους ελαχίστων τετραγώνων:

$$J(w) = \sum_{n=1}^N (y_n - w^T x_n)^2 = (y - Xw)^T (y - Xw)$$

Θα λύσουμε, δηλαδή την εξίσωση:

$$\frac{J(w)}{\partial w} = -2X^T(y - Xw) = 0 \Rightarrow$$

$$X^T y - X^T X w = 0 \Rightarrow$$

$$w = (X^T X)^{-1} X^T y$$

Συνεπώς, ο εκτιμητής ελαχίστων τετραγώνων είναι $\hat{w} = (X^T X)^{-1} X^T y$.

Ερώτημα γ

Μέση τιμή $\hat{w}$:

$$\begin{aligned} E[\hat{w}] &= & // \hat{w} &= (X^T X)^{-1} X^T y \\ E[(X^T X)^{-1} X^T y] &= & // y &= Xw + \varepsilon \\ E[(X^T X)^{-1} X^T (Xw + \varepsilon)] &= & // \text{επιμεριστική ιδιότητα} \\ E[(X^T X)^{-1} X^T Xw + (X^T X)^{-1} X^T \varepsilon] &= & // \text{γραμμικότητα μέσης τιμής} \\ E[(X^T X)^{-1} X^T Xw] + E[(X^T X)^{-1} X^T \varepsilon] &= & // (X^T X)^{-1} X^T Xw \text{ σταθερά} \\ (X^T X)^{-1} X^T Xw + (X^T X)^{-1} X^T E[\varepsilon] &= & // \varepsilon \sim \mathcal{N}(0, \sigma^2 I) \Rightarrow E[\varepsilon] = 0 \\ (X^T X)^{-1} X^T Xw &= & // (X^T X)^{-1} = X^{-1} (X^T)^{-1} \\ X^{-1} (X^T)^{-1} X^T Xw &= & // (X^T)^{-1} X^T = I \\ X^{-1} Xw &= & // X^{-1} X = I \end{aligned}$$

w

Συνεπώς, ο εκτιμητής ελαχίστων τετραγώνων $\hat{w}$ είναι αμερόληπτος, δηλαδή $E[\hat{w}] = w$.

Υπολογισμός $\hat{w} - w$:

$$\begin{aligned} \hat{w} - w &= & // \hat{w} &= (X^T X)^{-1} X^T y \\ (X^T X)^{-1} X^T y - w &= & // y &= Xw + \varepsilon \\ (X^T X)^{-1} X^T (Xw + \varepsilon) - w &= & // \text{επιμεριστική ιδιότητα} \\ (X^T X)^{-1} X^T Xw + (X^T X)^{-1} X^T \varepsilon - w &= & // (X^T X)^{-1} = X^{-1} (X^T)^{-1} \\ X^{-1} (X^T)^{-1} X^T Xw + X^{-1} (X^T)^{-1} X^T \varepsilon - w &= & // (X^T)^{-1} X^T = I \\ X^{-1} Xw + X^{-1} \varepsilon - w &= & // X^{-1} X = I \\ w + X^{-1} \varepsilon - w &= & // w - w = 0 \\ X^{-1} \varepsilon \end{aligned}$$

Άρα, $\hat{w} - w = X^{-1} \varepsilon$.

Πίνακας συμβατότητας του $\hat{w}$:

$$\begin{aligned} \text{Cov}(\hat{w}) &= & // \text{από ορισμό} \\ E[(\hat{w} - E[\hat{w}])(\hat{w} - E[\hat{w}])^T] &= & // E[\hat{w}] = w \\ E[(\hat{w} - w)(\hat{w} - w)^T] &= & // \hat{w} - w = X^{-1} \varepsilon \\ E[(X^{-1} \varepsilon)(X^{-1} \varepsilon)^T] &= & // (X^{-1} \varepsilon)^T = \varepsilon^T (X^{-1})^T \\ E[X^{-1} \varepsilon \varepsilon^T (X^{-1})^T] &= & // X^{-1}, (X^{-1})^T \text{ σταθερές} \\ X^{-1} E[\varepsilon \varepsilon^T] (X^{-1})^T &= & // \varepsilon \sim \mathcal{N}(0, \sigma^2 I) \Rightarrow E[\varepsilon \varepsilon^T] = \sigma^2 I \\ \sigma^2 X^{-1} (X^{-1})^T &= & // X^{-1} (X^{-1})^T = X^{-1} (X^T)^{-1} = (X^T X)^{-1} \\ \sigma^2 (X^T X)^{-1} \end{aligned}$$

Συνεπώς, ο πίνακας συμβατότητας (covariance matrix) του $\hat{w}$ είναι $\text{Cov}(\hat{w}) = \sigma^2 (X^T X)^{-1}$.

Ερώτημα δ

Έστω $\hat{y}_i = x_i^T \hat{w}$ και $\hat{y} = [\hat{y}_0, \hat{y}_1, \dots, \hat{y}_N]^T$.

Ισχύει ότι $\hat{y} = X\hat{w} = X(X^T X)^{-1} X^T y$.

Επίσης, ο πίνακας προβολής στον χώρο στηλών του X είναι $P = X(X^T X)^{-1} X^T$.

Συνεπώς, το $\hat{y}$ είναι η προβολή του y στον χώρο στηλών του X , καθώς $\hat{y} = Py$, και ακολουθεί κανονική κατανομή.

Μέση τιμή $\hat{y}$:

$$\begin{aligned} E[\hat{y}] &= & // \hat{y} &= Py \\ E[Py] &= & // y &= Xw + \varepsilon \\ E[P(Xw + \varepsilon)] &= & // \text{επιμεριστική ιδιότητα} \\ E[PXw + P\varepsilon] &= & // \text{γραμμικότητα μέσης τιμής} \\ E[PXw] + E[P\varepsilon] &= & // PXw, P \text{ σταθερές} \\ PXw + PE[\varepsilon] &= & // \varepsilon \sim \mathcal{N}(0, \sigma^2 I) \Rightarrow E[\varepsilon] = 0 \\ PXw & \end{aligned}$$

Συνεπώς, η μέση τιμή του $\hat{y}$ είναι $E[\hat{y}] = PXw$.

Διακύμανση $\hat{y}$:

$$\begin{aligned} \text{Cov}[\hat{y}] &= & // \hat{y} &= Py \\ \text{Cov}[Py] &= & // y &= Xw + \varepsilon \\ \text{Cov}[P(Xw + \varepsilon)] &= & // \text{επιμεριστική ιδιότητα} \\ \text{Cov}[PXw + P\varepsilon] &= & // PXw \text{ σταθερά} \\ \text{Cov}[P\varepsilon] &= & // \text{ιδιότητα} \\ P \text{Cov}[\varepsilon] P^T &= & // \varepsilon \sim \mathcal{N}(0, \sigma^2 I) \Rightarrow \text{Cov}[\varepsilon] = \sigma^2 I \\ \sigma^2 P P^T &= & // P \text{ συμμετρικός} \Rightarrow P^T = P \\ \sigma^2 P P &= & // P \text{ ιδιομορφικός} \Rightarrow P P = P \\ \sigma^2 P & \end{aligned}$$

Συνεπώς, η διακύμανση του $\hat{y}$ είναι $\text{Cov}[\hat{y}] = \sigma^2 P$.

Επομένως, το διάνυσμα $\hat{y}$ ακολουθεί κατανομή: $\hat{y} \sim \mathcal{N}(PXw, \sigma^2 P)$

Ερώτημα ε

Έστω $\hat{\varepsilon}_i = y_i - \hat{y}_i$ και $\hat{\varepsilon} = [\hat{\varepsilon}_0, \hat{\varepsilon}_1, \dots, \hat{\varepsilon}_N]^T$.

Το διάνυσμα των “ελαχίστων σφαλμάτων” $\hat{\varepsilon} = y - \hat{y} = y - Py = (I - P)y$ ακολουθεί κανονική κατανομή.

Μέση τιμή $\hat{\varepsilon}$:

$$\begin{aligned} E[\hat{\varepsilon}] &= & // \hat{\varepsilon} &= (I - P)y \\ E[(I - P)y] &= & // I - P \text{ σταθερά} \\ (I - P)E[y] &= & // E[y] = Xw \\ (I - P)Xw &= & // \text{επιμεριστική ιδιότητα} \\ Xw - PXw &= & // P \text{ πίνακας προβολής } X \Rightarrow PX = X \\ Xw - Xw &= & \\ 0 & \end{aligned}$$

Συνεπώς, η μέση τιμή του $\hat{\varepsilon}$ είναι $E[\hat{\varepsilon}] = 0$.

Διακύμανση $\hat{\varepsilon}$:

$$\begin{aligned} \text{Cov}[\hat{\varepsilon}] &= & // \hat{\varepsilon} &= (I - P)y \\ \text{Cov}[(I - P)y] &= & // \text{ιδιότητα} \\ (I - P)\text{Cov}[y](I - P)^T &= & // y \sim \mathcal{N}(Xw, \sigma^2 I) \Rightarrow \text{Cov}[y] = \sigma^2 I \\ \sigma^2 (I - P)(I - P)^T &= & // (I - P) \text{ συμμετρικός} \Rightarrow (I - P)^T = (I - P) \\ \sigma^2 (I - P)(I - P) &= & // (I - P) \text{ ιδιομορφικός} \Rightarrow (I - P)^2 = (I - P) \\ \sigma^2 (I - P) & \end{aligned}$$

Συνεπώς, η διακύμανση του $\hat{\epsilon}$ είναι $\text{Cov}[\hat{\epsilon}] = \sigma^2(I - P)$.

Επομένως, το διάνυσμα $\hat{\epsilon}$ ακολουθεί κατανομή: $\hat{\epsilon} \sim \mathcal{N}(0, \sigma^2(I - P))$.

Το σφάλμα ελαχίστων τετραγώνων $\hat{\epsilon}^T \hat{\epsilon} = \sum_{i=1}^N \hat{\epsilon}_i^2$ μπορεί να γραφεί ως εξής:

$$\begin{aligned} \hat{\epsilon}^T \hat{\epsilon} &= // \hat{\epsilon} = (I - P)y \\ ((I - P)y)^T (I - P)y &= // ((I - P)y)^T = y^T (I - P)^T \\ y^T (I - P)^T (I - P)y &= // (I - P) \text{ συμμετρικός } \Rightarrow (I - P)^T = (I - P) \\ y^T (I - P)(I - P)y &= // (I - P) \text{ ιδιομορφικός } \Rightarrow (I - P)^2 = (I - P) \\ y^T (I - P)y \end{aligned}$$

Συνεπώς, το σφάλμα ελαχίστων τετραγώνων μπορεί να γραφεί ως $\hat{\epsilon}^T \hat{\epsilon} = y^T (I - P)y$.

Άσκηση 1.2 (Multivariate Gaussian distribution)

Έχουμε ότι $x \sim \mathcal{N}(\mu_x = 5, \sigma_x^2 = 3^2)$, $y \sim \mathcal{N}(\mu_y = 10, \sigma_y^2 = 4^2)$ και $\rho = \frac{\text{Cov}(x,y)}{\sigma_x \sigma_y} = 0.6$

Κώδικας προγράμματος

Ερώτημα α

Η από κοινού συνάρτηση πυκνότητας (σ.π.π.) των x, y δίνεται ως εξής:

$$f(x, y) = \frac{1}{2\pi \sigma_x \sigma_y \sqrt{1 - \rho^2}} \exp \left(-\frac{1}{2(1 - \rho^2)} \left(\frac{(x - \mu_x)^2}{\sigma_x^2} - \frac{2\rho(x - \mu_x)(y - \mu_y)}{\sigma_x \sigma_y} + \frac{(y - \mu_y)^2}{\sigma_y^2} \right) \right)$$

Με αντικατάσταση:

$$f(x, y) = \frac{1}{2\pi * 3 * 4 \sqrt{1 - 0.6^2}} \exp \left(-\frac{1}{2(1 - 0.6^2)} \left(\frac{(x - 5)^2}{3^2} - \frac{2 * 0.6 * (x - 5)(y - 10)}{3 * 4} + \frac{(y - 10)^2}{4^2} \right) \right)$$

Με πράξεις:

$$f(x, y) = \frac{1}{19.2\pi} \exp \left(-\frac{1}{1.28} \left(\frac{(x - 5)^2}{9} - \frac{(x - 5)(y - 10)}{10} + \frac{(y - 10)^2}{16} \right) \right)$$

Ερώτημα β

Η υπό συνθήκη σ.π.π. $p(y|x = 6)$ ακολουθεί κατανομή $y|x = 6 \sim \mathcal{N}(\mu_{y|x=6}, \sigma_{y|x=6}^2)$.

Μέση τιμή $y|x = 6$:

$$\begin{aligned} \mu_{y|x} &= \mu_y + \rho \frac{\sigma_y}{\sigma_x} (x - \mu_x) \\ \mu_{y|x=6} &= 10 + 0.6 * \frac{4}{3} * (6 - 5) = 10.8 \end{aligned}$$

Διασπορά $y|x = 6$:

$$\begin{aligned} \sigma_{y|x}^2 &= \sigma_y^2 (1 - \rho^2) \\ \sigma_{y|x=6}^2 &= 4^2 (1 - 0.6^2) = 10.24 = 3.2^2 \end{aligned}$$

Συνεπώς, η υπό συνθήκη σ.π.π. $p(y|x = 6)$ ακολουθεί την εξής κανονική κατανομή:
 $y|x = 6 \sim \mathcal{N}(\mu_{y|x=6} = 10.8, \sigma_{y|x=6}^2 = 3.2^2)$.

$$p(y|x) = \frac{1}{\sigma_{y|x}\sqrt{2\pi}} \exp\left(-\frac{(y-\mu_{y|x})^2}{2\sigma_{y|x}^2}\right)$$

$$p(y|x=6) = \frac{1}{3.2\sqrt{2\pi}} \exp\left(-\frac{(y-10.8)^2}{2 \cdot 10.24}\right) = \frac{1}{3.2\sqrt{2\pi}} \exp\left(-\frac{(y-10.8)^2}{20.48}\right)$$

Για την πιθανότητα $p(y > 10 | x = 6)$ έχουμε ότι:

$$p(y > 10 | x = 6) = 1 - p(y \leq 10 | x = 6) = 1 - \Phi\left(\frac{10 - \mu_{y|x=6}}{\sigma_{y|x=6}}\right) = 1 - \Phi\left(\frac{10 - 10.8}{3.2}\right) = 1 - \Phi(-0.25) = 1 - 0.4013 = 0.5987 = 59.87\%$$

Επαλήθευση αποτελεσμάτων:

```
Conditional mean E[Y | X = 6]: 10.8000
Conditional standard deviation σ(Y | X = 6): 3.2000
Probability P(Y > 10 | X = 6): 0.5987
```

Ερώτημα γ

Η υπό συνθήκη σ.π.π. $p(x|y = 9)$ ακολουθεί κανονική κατανομή $x|y \sim N(\mu_{x|y=9}, \sigma_{x|y=9}^2)$

Μέση τιμή $x|y = 9$:

$$\mu_{x|y} = \mu_x + \rho \frac{\sigma_x}{\sigma_y} (y - \mu_y)$$

$$\mu_{x|y=9} = 5 + 0.6 \cdot \frac{3}{4} \cdot (9 - 10) = 4.55$$

Διασπορά $x|y = 9$:

$$\sigma_{x|y}^2 = \sigma_x^2 (1 - \rho^2)$$

$$\sigma_{x|y=9}^2 = 3^2 (1 - 0.6^2) = 5.76 = 2.4^2$$

Συνεπώς, η υπό συνθήκη σ.π.π. $p(x|y = 9)$ ακολουθεί την εξής κανονική κατανομή:
 $x|y \sim N(\mu_{x|y=9} = 4.55, \sigma_{x|y=9}^2 = 2.4^2)$.

$$p(x|y) = \frac{1}{\sigma_{x|y}\sqrt{2\pi}} \exp\left(-\frac{(x-\mu_{x|y})^2}{2\sigma_{x|y}^2}\right)$$

$$p(x|y=9) = \frac{1}{2.4\sqrt{2\pi}} \exp\left(-\frac{(x-4.55)^2}{2 \cdot 2.4^2}\right) = \frac{1}{2.4\sqrt{2\pi}} \exp\left(-\frac{(y-4.55)^2}{11.52}\right)$$

Για την πιθανότητα $p(x > 5 | y = 9)$ έχουμε ότι:

$$p(x > 5 | y = 9) = 1 - p(x \leq 5 | y = 9) = 1 - \Phi\left(\frac{5 - \mu_{x|y=9}}{\sigma_{x|y=9}}\right)$$

$$= 1 - \Phi\left(\frac{5 - 4.55}{2.4}\right) = 1 - \Phi(0.1875) = 1 - 0.5744 = 0.4256 = 42.56\%$$

Επαλήθευση αποτελεσμάτων:

```
Conditional mean E[X | Y = 9]: 4.5500
Conditional standard deviation σ(X | Y = 9): 2.4000
Probability P(X > 5 | Y = 9): 0.4256
```

Ερώτημα δ


Η εξίσωση της ισοσταθμικής καμπύλης στο σημείο $(x, y) = (6, 12)$ είναι η εξής:
 $f(x, y) = f(6, 12)$

$$\frac{(x-5)^2}{9} - \frac{(x-5)(y-10)}{10} + \frac{(y-10)^2}{16} = \frac{(6-5)^2}{9} - \frac{(6-5)(12-10)}{10} + \frac{(12-10)^2}{16}$$

$$\frac{(x-5)^2}{9} - \frac{(x-5)(y-10)}{10} + \frac{(y-10)^2}{16} = \frac{29}{180}$$

$$80x^2 + 72xy + 45y^2 - 1520x - 1260y + 9984 = 0$$

Συνεπώς, η ισοσταθμική καμπύλη στο σημείο $(x, y) = (6, 12)$ είναι έλλειψη.



Άσκηση 1.3 (Bayes classifier – 3 classes)

Θεωρούμε το πρόβλημα ταξινόμησης σε τρεις κλάσεις στο R^2 .

Οι prior πιθανότητες είναι $P(\omega_1) = 0.2, P(\omega_2) = 0.5, P(\omega_3) = 0.3$.

Οι κατανομές είναι $x|\omega_1 \sim N(\mu_1, \Sigma), x|\omega_2 \sim N(\mu_2, \Sigma), x|\omega_3 \sim N(\mu_3, \Sigma)$.

Οι παράμετροι των κατανομών είναι $\mu_1 = \begin{bmatrix} 3 \\ -2 \end{bmatrix}, \mu_2 = \begin{bmatrix} 4 \\ 3 \end{bmatrix}, \mu_3 = \begin{bmatrix} 6 \\ 7 \end{bmatrix}, \Sigma = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix}$

Κώδικας προγράμματος

Ερώτημα α

Έστω νέα παρατήρηση $x = [3 \ 5]^T$.

Αρχικά, θα υπολογίσουμε τις δεσμευμένες πιθανότητες $P(x | \omega_i)$.

$$P(x | \omega_i) = \frac{1}{2\pi\sqrt{|\Sigma|}} \exp\left(-\frac{1}{2}(x - \mu_i)^T \Sigma^{-1}(x - \mu_i)\right)$$

Έπειτα, θα υπολογίσουμε την πιθανότητα $P(x) = \sum_{i=1}^3 P(x | \omega_i)P(\omega_i)$.

Τέλος, θα υπολογίσουμε τις posterior πιθανότητες αξιοποιώντας τον κανόνα του Bayes.

$$P(\omega_i | x) = \frac{P(x|\omega_i)P(\omega_i)}{p(x)}$$

Ισχύει ότι:

$$|\Sigma| = \begin{vmatrix} 1 & 0.5 \\ 0.5 & 1 \end{vmatrix} = 1 - 0.25 = 0.75$$

$$\Sigma^{-1} = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix}^{-1} = \frac{1}{0.75} \begin{bmatrix} 1 & -0.5 \\ -0.5 & 1 \end{bmatrix} = \begin{bmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{bmatrix}$$

Δεσμευμένη πιθανότητα $P(x | \omega_1)$:

$$P(x | \omega_1) = \frac{1}{2\pi\sqrt{|\Sigma|}} \exp\left(-\frac{1}{2}(x - \mu_1)^T \Sigma^{-1}(x - \mu_1)\right)$$

$$P(x | \omega_1) = \frac{1}{2\pi\sqrt{0.75}} \exp\left(-\frac{1}{2}\left(\begin{bmatrix} 3 \\ 5 \end{bmatrix} - \begin{bmatrix} 3 \\ -2 \end{bmatrix}\right)^T \begin{bmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{bmatrix} \left(\begin{bmatrix} 3 \\ 5 \end{bmatrix} - \begin{bmatrix} 3 \\ -2 \end{bmatrix}\right)\right)$$

$$P(x | \omega_1) = \frac{1}{\pi\sqrt{3}} \exp\left(-\frac{1}{2} \begin{bmatrix} 0 & 7 \end{bmatrix} \begin{bmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{bmatrix} \begin{bmatrix} 0 \\ 7 \end{bmatrix}\right)$$

$$P(x | \omega_1) = \frac{1}{\pi\sqrt{3}} \exp\left(-\frac{98}{3}\right)$$

$$P(x | \omega_1) = 1.19491338 * 10^{-15} \approx 0$$

Δεσμευμένη πιθανότητα $P(x | \omega_2)$:

$$P(x | \omega_2) = \frac{1}{2\pi\sqrt{|\Sigma|}} \exp\left(-\frac{1}{2}(x - \mu_2)^T \Sigma^{-1}(x - \mu_2)\right)$$

$$P(x | \omega_2) = \frac{1}{2\pi\sqrt{0.75}} \exp\left(-\frac{1}{2}\left(\begin{bmatrix} 3 \\ 5 \end{bmatrix} - \begin{bmatrix} 6 \\ 7 \end{bmatrix}\right)^T \begin{bmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{bmatrix} \left(\begin{bmatrix} 3 \\ 5 \end{bmatrix} - \begin{bmatrix} 6 \\ 7 \end{bmatrix}\right)\right)$$

$$P(x | \omega_2) = \frac{1}{\pi\sqrt{3}} \exp\left(-\frac{1}{2} \begin{bmatrix} -3 & -2 \end{bmatrix} \begin{bmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{bmatrix} \begin{bmatrix} -3 \\ -2 \end{bmatrix}\right)$$

$$P(x | \omega_2) = \frac{1}{\pi\sqrt{3}} \exp\left(-\frac{14}{3}\right)$$

$$P(x | \omega_2) = 0.001781519$$

Δεσμευμένη πιθανότητα $P(x | \omega_3)$:

$$P(x | \omega_3) = \frac{1}{2\pi\sqrt{|\Sigma|}} \exp\left(-\frac{1}{2}(x - \mu_3)^T \Sigma^{-1}(x - \mu_3)\right)$$

$$P(x | \omega_3) = \frac{1}{2\pi\sqrt{0.75}} \exp\left(-\frac{1}{2}\left(\begin{bmatrix} 3 \\ 5 \end{bmatrix} - \begin{bmatrix} 4 \\ 3 \end{bmatrix}\right)^T \begin{bmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{bmatrix} \left(\begin{bmatrix} 3 \\ 5 \end{bmatrix} - \begin{bmatrix} 4 \\ 3 \end{bmatrix}\right)\right)$$

$$P(x | \omega_3) = \frac{1}{\pi\sqrt{3}} \exp\left(-\frac{1}{2} \begin{bmatrix} -1 & 2 \end{bmatrix} \begin{bmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{bmatrix} \begin{bmatrix} -1 \\ 2 \end{bmatrix}\right)$$

$$P(x | \omega_3) = \frac{1}{\pi\sqrt{3}} \exp\left(-\frac{14}{3}\right)$$

$$P(x | \omega_3) = 0.001781519$$

Πιθανότητα $P(x)$:

$$P(x) = \sum_{i=1}^3 P(x | \omega_i) P(\omega_i)$$

$$P(x) = P(x | \omega_1) P(\omega_1) + P(x | \omega_2) P(\omega_2) + P(x | \omega_3) P(\omega_3)$$

$$P(x) = P(x | \omega_1) P(\omega_1) + P(x | \omega_2) P(\omega_2) + P(x | \omega_3) P(\omega_3)$$

$$P(x) = \frac{1}{\pi\sqrt{3}} \exp\left(-\frac{98}{3}\right) * 0.2 + \frac{1}{\pi\sqrt{3}} \exp\left(-\frac{14}{3}\right) * 0.5 + \frac{1}{\pi\sqrt{3}} \exp\left(-\frac{14}{3}\right) * 0.3$$

$$P(x) = 0.0013852$$

Posterior πιθανότητα $p(\omega_1 | x)$:

$$P(\omega_1 | x) = \frac{P(x|\omega_1)P(\omega_1)}{P(x)}$$

$$P(\omega_1 | x) = \frac{\frac{1}{\pi\sqrt{3}} \exp\left(-\frac{98}{3}\right) * 0.2}{\frac{1}{\pi\sqrt{3}} \exp\left(-\frac{98}{3}\right) * 0.2 + \frac{1}{\pi\sqrt{3}} \exp\left(-\frac{14}{3}\right) * 0.5 + \frac{1}{\pi\sqrt{3}} \exp\left(-\frac{14}{3}\right) * 0.3}$$

$$P(\omega_1 | x) = 1.7286 * 10^{-13}$$

Posterior πιθανότητα $p(\omega_2 | x)$:

$$P(\omega_2 | x) = \frac{P(x|\omega_2)P(\omega_2)}{P(x)}$$

$$P(\omega_2 | x) = \frac{\frac{1}{\pi\sqrt{3}} \exp\left(-\frac{14}{3}\right) * 0.5}{\frac{1}{\pi\sqrt{3}} \exp\left(-\frac{98}{3}\right) * 0.2 + \frac{1}{\pi\sqrt{3}} \exp\left(-\frac{14}{3}\right) * 0.5 + \frac{1}{\pi\sqrt{3}} \exp\left(-\frac{14}{3}\right) * 0.3}$$

$$P(\omega_2 | x) = 0.625$$

Posterior πιθανότητα $p(\omega_3 | x)$:

$$P(\omega_3 | x) = \frac{P(x|\omega_3)P(\omega_3)}{P(x)}$$

$$P(\omega_3 | x) = \frac{\frac{1}{\pi\sqrt{3}} \exp\left(-\frac{14}{3}\right) * 0.3}{\frac{1}{\pi\sqrt{3}} \exp\left(-\frac{98}{3}\right) * 0.2 + \frac{1}{\pi\sqrt{3}} \exp\left(-\frac{14}{3}\right) * 0.5 + \frac{1}{\pi\sqrt{3}} \exp\left(-\frac{14}{3}\right) * 0.3}$$

$$P(\omega_3 | x) = 0.375$$

Επαλήθευση αποτελεσμάτων:

```
Likelihoods for x = [3 5] : P[x | wi] = ['0.0000', '0.0017', '0.0017']
Total probability for x = [3 5] : P(x) = 0.0014
Posterior probabilities for x = [3 5] : P[wi|x] = ['0.0000', '0.6250', '0.3750']
```

Ερώτημα β

Ισχύει ότι $P(\omega_2 | x) > P(\omega_3 | x) > P(\omega_1 | x) \Rightarrow \arg \max_{\omega_j} P(\omega_j | x) = \omega_2$

Με βάση τον κανόνα ταξινόμησης κατά Bayes το πρότυπο $x = (3, 5)$ θα ταξινομηθεί στην κλάση $\omega_1 = \arg \max_{\omega_j} P(\omega_j | x)$, δηλαδή στην ω_2 .

Επαλήθευση αποτελέσματος:

```
Point x = [3 5] is classified in class 2
```

Ερώτημα γ

Για ένα ζεύγους κλάσεων (w_i, w_j) :

Συναρτήσεις διάκρισης:

$$g_i(x) = \ln(P(\omega_i | x)) = \ln(P(x | \omega_i)) - \ln(P(\omega_i))$$

$$g_j(x) = \ln(P(\omega_j | x)) = \ln(P(x | \omega_j)) - \ln(P(\omega_j))$$

Υπερ-επιφάνεια απόφασης:

$$g_{ij}(x) = g_i(x) - g_j(x) = 0$$

$$g_{ij}(x) = \frac{1}{2}(x^T \Sigma_j^{-1} x - x^T \Sigma_i^{-1} x) + \mu_i^T \Sigma_i^{-1} x - \mu_j^T \Sigma_j^{-1} x - \frac{1}{2} \mu_i^T \Sigma_i^{-1} \mu_i + \frac{1}{2} \mu_j^T \Sigma_j^{-1} \mu_j +$$

$$\ln\left(\frac{P(\omega_i)}{P(\omega_j)}\right) + \frac{1}{2} \ln\left(\frac{|\Sigma_j|}{|\Sigma_i|}\right) = 0$$

Για $\Sigma_i = \Sigma_j = \Sigma$:

$$g_{ij}(x) = \mu_i^T \Sigma^{-1} x - \mu_j^T \Sigma^{-1} x - \frac{1}{2} \mu_i^T \Sigma^{-1} \mu_i + \frac{1}{2} \mu_j^T \Sigma^{-1} \mu_j + \ln \left(\frac{P(\omega_i)}{P(\omega_j)} \right) = 0$$

$$g_{ij}(x) = (\mu_i^T - \mu_j^T) \Sigma^{-1} x + \frac{1}{2} (\mu_j^T \Sigma^{-1} \mu_j - \mu_i^T \Sigma^{-1} \mu_i) + \ln \left(\frac{P(\omega_i)}{P(\omega_j)} \right) = 0$$

$$g_{ij}(x) = (\mu_i - \mu_j)^T (\Sigma^{-1})^T x + \frac{1}{2} (\mu_j^T \Sigma^{-1} \mu_j - \mu_i^T \Sigma^{-1} \mu_i) + \ln \left(\frac{P(\omega_i)}{P(\omega_j)} \right) = 0$$

$$g_{ij}(x) = ((\Sigma^{-1})(\mu_i - \mu_j))^T x + \frac{1}{2} (\mu_j^T \Sigma^{-1} \mu_j - \mu_i^T \Sigma^{-1} \mu_i) + \ln \left(\frac{P(\omega_i)}{P(\omega_j)} \right) = 0$$

Συνεπώς, $g_{ij}(x) = w_{ij}^T x + w_{0ij} = 0$, όπου:

$$w_{ij} = ((\Sigma^{-1})(\mu_i - \mu_j))^T \quad \text{και} \quad w_{0ij} = \frac{1}{2} (\mu_j^T \Sigma^{-1} \mu_j - \mu_i^T \Sigma^{-1} \mu_i) + \ln \left(\frac{P(\omega_i)}{P(\omega_j)} \right)$$

Έχουμε ότι:

$$\mu_1^T \Sigma^{-1} \mu_1 = [3 \quad -2] \begin{bmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{bmatrix} \begin{bmatrix} 3 \\ -2 \end{bmatrix} = \frac{76}{3}$$

$$\mu_2^T \Sigma^{-1} \mu_2 = [4 \quad 3] \begin{bmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{bmatrix} \begin{bmatrix} 4 \\ 3 \end{bmatrix} = \frac{52}{3}$$

$$\mu_3^T \Sigma^{-1} \mu_3 = [6 \quad 7] \begin{bmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{bmatrix} \begin{bmatrix} 6 \\ 7 \end{bmatrix} = \frac{172}{3}$$

Υπερ-επιφάνεια απόφασης κλάσεων (w_1, w_2):

$$g_{12}(x) = w_{12}^T x + w_{012} = 0$$

$$w_{12} = (\Sigma^{-1})(\mu_1 - \mu_2) = \begin{bmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{bmatrix} \left(\begin{bmatrix} 3 \\ -2 \end{bmatrix} - \begin{bmatrix} 4 \\ 3 \end{bmatrix} \right) = \begin{bmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{bmatrix} \begin{bmatrix} -1 \\ -5 \end{bmatrix} = \begin{bmatrix} 2 \\ -6 \end{bmatrix}$$

$$w_{012} = \frac{1}{2} (\mu_2^T \Sigma^{-1} \mu_2 - \mu_1^T \Sigma^{-1} \mu_1) + \ln \left(\frac{P(\omega_1)}{P(\omega_2)} \right) = \frac{1}{2} \left(\frac{52}{3} - \frac{76}{3} \right) + \ln \left(\frac{0.2}{0.5} \right) = -4.916291$$

$$g_{12}(x) = [2 \quad -6] \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} - 4.91629 = 0$$

$$2x_1 - 6x_2 - 4.91629 = 0$$

Υπερ-επιφάνεια απόφασης κλάσεων (w_2, w_3):

$$g_{23}(x) = w_{23}^T x + w_{023} = 0$$

$$w_{23} = (\Sigma^{-1})(\mu_2 - \mu_3) = \begin{bmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{bmatrix} \left(\begin{bmatrix} 4 \\ 3 \end{bmatrix} - \begin{bmatrix} 6 \\ 7 \end{bmatrix} \right) = \begin{bmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{bmatrix} \begin{bmatrix} -2 \\ -4 \end{bmatrix} = \begin{bmatrix} 0 \\ -4 \end{bmatrix}$$

$$w_{023} = \frac{1}{2} (\mu_3^T \Sigma^{-1} \mu_3 - \mu_2^T \Sigma^{-1} \mu_2) + \ln \left(\frac{P(\omega_2)}{P(\omega_3)} \right) = \frac{1}{2} \left(\frac{172}{3} - \frac{52}{3} \right) + \ln \left(\frac{0.5}{0.3} \right) = 20.51083$$

$$g_{23}(x) = [0 \quad -4] \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + 20.51083 = 0$$

$$-4x_2 + 20.51083 = 0$$

Υπερ-επιφάνεια απόφασης κλάσεων (w_3, w_1):


$$g_{31}(x) = w_{31}^T x + w_{031} = 0$$

$$w_{31} = (\Sigma^{-1})(\mu_3 - \mu_1) = \begin{bmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{bmatrix} \left(\begin{bmatrix} 6 \\ 7 \end{bmatrix} - \begin{bmatrix} 3 \\ -2 \end{bmatrix} \right) = \begin{bmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{bmatrix} \begin{bmatrix} 3 \\ 9 \end{bmatrix} = \begin{bmatrix} -2 \\ 10 \end{bmatrix}$$

$$w_{0_{31}} = \frac{1}{2}(\mu_1^T \Sigma^{-1} \mu_1 - \mu_3^T \Sigma^{-1} \mu_3) + \ln \left(\frac{P(\omega_3)}{P(\omega_1)} \right) = \frac{1}{2} \left(\frac{76}{3} - \frac{172}{3} \right) + \ln \left(\frac{0.3}{0.2} \right) = -15.59453$$


$$g_{31}(x) = [-2 \quad 10] \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} - 15.59453 = 0$$

$$-2x_1 + 10x_2 + 20.51083 = 0$$



Ερώτημα δ

Στο παρακάτω σχήμα φαίνονται 500 σημεία από κάθε μία από τις κατανομές, τα κέντρα των κλάσεων και οι βέλτιστες καμπύλες απόφασης.



Ερώτημα ε

Έστω μια παρατήρηση x που ανήκει στην κλάση ω_2 . Η πιθανότητα λανθασμένης ταξινόμησης του x , αν πραγματοποιήσουμε ταξινόμηση κατά Bayes, είναι περίπου 2%.

Αυτό το αποτέλεσμα προέκυψε έπειτα από ταξινόμηση 10.000 samples, τα οποία ανήκαν στην class ω_2 , και απαρίθμηση των samples που λανθασμένα ταξινομήθηκαν στις κλάσεις 1 και 3.

Misclassification probability when true class is ω_2 for 10000 samples: 0.0189

Άσκηση1.4 (Perceptron - Multilayer Perceptron)

Θεωρήστε επέκταση του μη-γραμμικά διαχωρίσιμου προβλήματος XOR, στην οποία:

input: $x_1, x_2 \in \{0, 1, 2\}$

output: $y = (x_1 + x_2) \bmod (3) \Rightarrow y = \{0, 1, 2\}$

Κώδικας προγράμματος

Ερώτημα α

Πίνακας input-output:

x_1	x_2	$y = (x_1 + x_2) \bmod (3)$
0	0	0
0	1	1
0	2	2
1	0	1
1	1	2
1	2	0
2	0	2
2	1	0
2	2	1

Class 0:	(0, 0), (1, 2), (2, 1)
Class 1:	(0, 1), (1, 0), (2, 2)
Class 2:	(0, 2), (1, 1), (2, 0)

Θα δημιουργήσουμε έναν πιθανό ταξινομητή τύπου MLP με μη γραμμική συνάρτηση επιλογής και με τον ελάχιστο δυνατό αριθμό νευρώνων. Προκειμένου να το πετύχουμε αυτό θα χρειαστούμε τέσσερις νευρώνες στο κρυφό επίπεδο και θα αξιοποιήσουμε ως μη γραμμική συνάρτηση ενεργοποίησης την βηματική (διπολική) συνάρτηση:

$$f(u) = \begin{cases} -1, & u < 0 \\ 1, & u > 0 \end{cases}$$

Η αρχιτεκτονική θα έχει την εξής μορφή:

Είσοδοι: Δύο νευρώνες εισόδου για τα x_1 και x_2 , όπου $x_1, x_2 \in \{0, 1, 2\}$.

Κρυφό επίπεδο: Τέσσερις νευρώνες

Νευρώνας h_1 : $f(x_1 + x_2 - 0.5)$

- Βάρη: $w_{h1,x1} = 1, w_{h1,x2} = 1$
- Πολώσεις: $b_{h1} = -0.5$
- Συνάρτηση: $f(u)$

Νευρώνας h_2 : $f(x_1 + x_2 - 1.5)$

- Βάρη: $w_{h_2,x_1} = 1, w_{h_2,x_2} = 1$
- Πολώσεις: $b_{h_2} = -1.5$
- Συνάρτηση: $f(u)$

Νευρώνας h_3 : $f(x_1 + x_2 - 2.5)$

- Βάρη: $w_{h_3,x_1} = 1, w_{h_3,x_2} = 1$
- Πολώσεις: $b_{h_3} = -2.5$
- Συνάρτηση: $f(u)$

Νευρώνας h_4 : $f(x_1 + x_2 - 3.5)$

- Βάρη: $w_{h_4,x_1} = 1, w_{h_4,x_2} = 1$
- Πολώσεις: $b_{h_4} = -3.5$
- Συνάρτηση: $f(u)$

x_1	x_2	$x_1 + x_2$	Ενεργοποιημένοι κρυφοί νευρώνες	Επιθυμητός νευρώνας εξόδου
0	0	0	-	y_0
0	1	1	h_1	y_1
1	0	1	h_1	y_1
0	2	2	h_1, h_2	y_2
1	1	2	h_1, h_2	y_2
2	0	2	h_1, h_2	y_2
1	2	3	h_1, h_2, h_3	y_0
2	1	3	h_1, h_2, h_3	y_0
2	2	4	h_1, h_2, h_3, h_4	y_1

Επιθυμητός νευρώνας εξόδου	Ενεργοποιημένοι κρυφοί νευρώνες (h_1, h_2, h_3, h_4)
y_0	$(-1, -1, -1, -1), (1, 1, 1, -1)$
y_1	$(1, -1, -1, -1), (1, 1, 1, 1)$
y_2	$(1, 1, -1, -1)$

Εξόδος: Τρεις νευρώνες εξόδου για τα y_0, y_1, y_2

Νευρώνας y_0 : $f(-y_{h1} + y_{h3} - y_{h4} - 0.5)$


- Βάρη: $w_{y_0,h_1} = -1, w_{y_0,h_2} = 0, w_{y_0,h_3} = 1, w_{y_0,h_4} = -1$
- Πολώσεις: $b_{y_0} = -0.5$
- Συνάρτηση: $f(u)$

Νευρώνας y_1 : $f(y_{h1} - y_{h2} + y_{h4} + 0.5)$

- Βάρη: $w_{y_1,h_1} = 1, w_{y_1,h_2} = -2, w_{y_1,h_3} = 0, w_{y_1,h_4} = 1$
- Πολώσεις: $b_{y_1} = 0.5$
- Συνάρτηση: $f(u)$


Νευρώνας y_2 : $f(y_{h2} - y_{h3} - 0.5)$

- Βάρη: $w_{y_2,h1} = 0$, $w_{y_2,h2} = 1$, $w_{y_2,h3} = -1$, $w_{y_2,h4} = 0$
- Πολώσεις: $b_{y_2} = -0.5$
- Συνάρτηση: $f(u)$



Ερώτημα β

Στο παρακάτω διάγραμμα φαίνονται τα στοιχεία με τις εξόδους τους, καθώς και οι περιοχές απόφασης για κάθε κλάση.



Ερώτημα γ

Επαλήθευση σχεδιασμού:

x1	x2	(x1+x2)%3	Predictiton	Result
0	0	0	0	True
0	1	1	1	True
0	2	2	2	True
1	0	1	1	True
1	1	2	2	True
1	2	0	0	True
2	0	2	2	True
2	1	0	0	True
2	2	1	1	True

Άσκηση1.5 (Support Vector Machines - Kernels)

Ερώτημα α

Οι συναρτήσεις πυρήνα (kernel functions) ορίζουν έμμεσα μια συνάρτηση απεικόνισης $\varphi(\cdot)$ που μετασχηματίζει ένα δείγμα εισόδου $x \in \mathbb{R}^d$ σε έναν χώρο υψηλής διάστασης Q , δίνοντας τη μορφή του εσωτερικού γινομένου στον Q : $K(x_i, x_j) \equiv \langle \varphi(x_i), \varphi(x_j) \rangle$.

Ερώτημα α1

Για τον πυρήνα ισχύει ότι:

$$K(x_i, x_j) = \langle \varphi(x_i), \varphi(x_j) \rangle \quad // \text{ ιδιότητα εσωτερικού γινομένου: } \langle a, b \rangle = \langle b, a \rangle$$

$$K(x_i, x_j) = \langle \varphi(x_j), \varphi(x_i) \rangle \quad // \text{ ορισμός πυρήνα: } \langle \varphi(x_j), \varphi(x_i) \rangle = K(x_j, x_i)$$

$$K(x_i, x_j) = K(x_j, x_i)$$

Συνεπώς, ισχύει ότι $K(x_i, x_j) = K(x_j, x_i)$ και ο πυρήνας είναι συμμετρικός.

Ερώτημα α2

Έστω ότι χρησιμοποιούμε συνάρτηση πυρήνα RBF (radial basis function):

$$K(x_i, x_j) = \exp\left(-\frac{1}{2}\|x_i - x_j\|^2\right)$$

Επομένως, υπάρχει μια έμμεσα ορισμένη και άγνωστη συνάρτηση απεικόνισης $\varphi(x)$.

$$\text{Ισχύει ότι: } K(x_i, x_i) = \langle \varphi(x_i), \varphi(x_i) \rangle = \|\varphi(x_i)\|^2 = \exp\left(-\frac{1}{2}\|x_i - x_i\|^2\right) = \exp(0) = 1$$

$$\text{Συνεπώς, } \|\varphi(x_i)\|^2 = \|\varphi(x_j)\|^2 = 1.$$

Επιπλέον, ισχύει ότι:

$$\|\varphi(x_i) - \varphi(x_j)\|^2 = \|\varphi(x_i)\|^2 + \|\varphi(x_j)\|^2 - 2 \langle \varphi(x_i), \varphi(x_j) \rangle$$

$$\|\varphi(x_i) - \varphi(x_j)\|^2 = \|\varphi(x_i)\|^2 + \|\varphi(x_j)\|^2 - 2 K(x_i, x_j)$$

$$\|\varphi(x_i) - \varphi(x_j)\|^2 = 1 + 1 - 2 \exp\left(-\frac{1}{2}\|x_i - x_j\|^2\right)$$

$$\|\varphi(x_i) - \varphi(x_j)\|^2 = 2 \left(1 - \exp\left(-\frac{1}{2}\|x_i - x_j\|^2\right)\right)$$

$$\|\varphi(x_i) - \varphi(x_j)\|^2 \leq 2$$

Συνεπώς, για οποιεσδήποτε δύο εισόδους x_i, x_j , η τετραγωνική Ευκλείδεια απόσταση των αντίστοιχων σημείων τους στον χώρο χαρακτηριστικών Q είναι μικρότερη από 2, δηλαδή $\|\varphi(x_i) - \varphi(x_j)\|^2 \leq 2$.

Ερώτημα β

Με τη βοήθεια της συνάρτησης πυρήνα, ένα SVM προσπαθεί να κατασκευάσει ένα υπερ-επίπεδο στον χώρο χαρακτηριστικών Q , ο οποίος μεγιστοποιεί το περιθώριο μεταξύ δύο κλάσεων. Η απόφαση ταξινόμησης για οποιοδήποτε x λαμβάνεται με βάση το πρόσημο της ποσότητας:

$$\langle \hat{w}, \varphi(x) \rangle + \hat{w}_0 = \sum_{i \in SV} y_i \alpha_i K(x_i, x) + \hat{w}_0 = f(x; \alpha, \hat{w}_0)$$

$\hat{w}, \hat{w}_0$ παράμετροι του υπερ-επιπέδου ταξινόμησης στον χώρο χαρακτηριστικών Q ,
 SV το σύνολο των διανυσμάτων στήριξης
 α_i ο συντελεστής για το i -στο διάνυσμα στήριξης.

Έστω ότι χρησιμοποιούμε ξανά τη συνάρτηση πυρήνα RBF και ότι τα δείγματα εκπαίδευσης είναι γραμμικά διαχωρίσιμα στον χώρο χαρακτηριστικών Q και ότι το SVM βρίσκει ένα περιθώριο που διαχωρίζει τέλεια τα σημεία.

Επιλέγουμε ένα σημείο ελέγχου x_{far} που βρίσκεται μακριά από οποιοδήποτε δείγμα εκπαίδευσης x_i (η απόσταση εδώ μετριέται στον αρχικό χώρο R^d).

Για $\|x_i - x_{far}\| \gg 1$ ισχύει ότι:

$$\sum_{i \in SV} y_i \alpha_i K(x_i, x_{far}) = \sum_{i \in SV} y_i \alpha_i \exp\left(-\frac{1}{2} \|x_i - x_{far}\|^2\right) \rightarrow 0$$

Ισχύει ότι:

$$\begin{aligned} f(x_{far}; \alpha, \hat{w}_0) &= \sum_{i \in SV} y_i \alpha_i K(x_i, x_{far}) + \hat{w}_0 \rightarrow 0 + \hat{w}_0 \\ f(x_{far}; \alpha, \hat{w}_0) &\rightarrow \hat{w}_0 \end{aligned}$$

Συνεπώς, έχουμε ότι $f(x_{far}; \alpha, \hat{w}_0) \approx \hat{w}_0$.

Κώδικες Προγραμμάτων

Άσκηση 1.2 (python code)

```
import numpy as np
import scipy.stats as stats
import matplotlib.pyplot as plt

# Parameters
mean_x = 5
std_dev_x = 3
mean_y = 10
std_dev_y = 4
correlation = 0.6

# Joint PDF function for bivariate normal distribution
def joint_pdf(x, y, mean_x, std_dev_x, mean_y, std_dev_y, correlation):
    coeff = 1 / (2 * np.pi * std_dev_x * std_dev_y * np.sqrt(1 - correlation**2))
    exponent = -1 / (2 * (1 - correlation**2)) * (
        ((x - mean_x)**2 / std_dev_x**2)
        - 2 * correlation * (x - mean_x) * (y - mean_y) / (std_dev_x * std_dev_y)
        + ((y - mean_y)**2 / std_dev_y**2)
    )
    return coeff * np.exp(exponent)

# Conditional mean of Z given W = w_value
def conditional_mean(m_z, s_z, m_w, s_w, correlation, w_value):
    return m_z + correlation * (s_z / s_w) * (w_value - m_w)

# Conditional standard deviation of Z
def conditional_std_dev(s_z, correlation):
    return s_z * np.sqrt(1 - correlation**2)

# Probability P(Z > z_value | W = w_value)
def conditional_prob_z_gt(z_mean_given_w, z_std_dev_given_w, z_value):
    return 1 - stats.norm.cdf(z_value, z_mean_given_w, z_std_dev_given_w)

# Calculate conditional statistics for P(Y | X = x_value)
x_value = 6
```

```

mean_y_given_x = conditional_mean(mean_y, std_dev_y, mean_x, std_dev_x, correlation, x_value)
std_dev_y_given_x = conditional_std_dev(std_dev_y, correlation)
print(f"Conditional mean  $E[Y | X = 6]$ : {mean_y_given_x:.4f}")
print(f"Conditional standard deviation  $\sigma(Y | X = 6)$ : {std_dev_y_given_x:.4f}")

# Probability  $P(Y > 10 | X = 6)$ 
y_threshold = 10
prob_y_gt_given_x = conditional_prob_z_gt(mean_y_given_x, std_dev_y_given_x, y_threshold)
print(f"Probability  $P(Y > 10 | X = 6)$ : {prob_y_gt_given_x:.4f}\n")

# Calculate conditional statistics for  $P(X | Y = y\_value)$ 
y_value = 9
mean_x_given_y = conditional_mean(mean_x, std_dev_x, mean_y, std_dev_y, correlation, y_value)
std_dev_x_given_y = conditional_std_dev(std_dev_x, correlation)
print(f"Conditional mean  $E[X | Y = 9]$ : {mean_x_given_y:.4f}")
print(f"Conditional standard deviation  $\sigma(X | Y = 9)$ : {std_dev_x_given_y:.4f}")

# Probability  $P(X > 5 | Y = 9)$ 
x_threshold = 5
prob_x_gt_given_y = conditional_prob_z_gt(mean_x_given_y, std_dev_x_given_y, x_threshold)
print(f"Probability  $P(X > 5 | Y = 9)$ : {prob_x_gt_given_y:.4f}\n")

# Joint PDF at specific point (6, 12)
joint_pdf_value = joint_pdf(6, 12, mean_x, std_dev_x, mean_y, std_dev_y, correlation)
print(f"Joint PDF at (6, 12): {joint_pdf_value:.4f}\n")

# Plot
x_min, x_max = mean_x - std_dev_x, mean_x + std_dev_x
y_min, y_max = mean_y - std_dev_y, mean_y + std_dev_y
x = np.linspace(x_min, x_max, 100)
y = np.linspace(y_min, y_max, 100)
X, Y = np.meshgrid(x, y)
Z = joint_pdf(X, Y, mean_x, std_dev_x, mean_y, std_dev_y, correlation)

plt.figure(figsize=(10, 8))
contour_plot = plt.contourf(X, Y, Z, levels=50)
plt.colorbar(contour_plot, label='Density')
plt.contour(X, Y, Z, levels=[joint_pdf_value], colors='red', linewidths=2, linestyles='-')

plt.title("Isoline at (6, 12)")

```

```
plt.xlabel('X')
plt.ylabel('Y')
plt.xlim(x_min, x_max)
plt.ylim(y_min, y_max)
plt.grid(True)
plt.show()
```

Άσκηση1.3 (python code)

```
import numpy as np
import matplotlib.pyplot as plt
from matplotlib.patches import Patch

# Input
m1, m2, m3 = [3, -2], [4, 3], [6, 7]
means = [m1, m2, m3]
S = np.array([[1, 0.5], [0.5, 1]])
S_inv = np.linalg.inv(S)
S_det = np.linalg.det(S)
priors = np.array([0.2, 0.5, 0.3])

# Gaussian probability  $x \sim N(m, S)$ 
def gaussian_prob(x, m, S_inv, S_det):
    diff = x - m
    exponent = -0.5 * np.dot(diff.T, np.dot(S_inv, diff))
    return (1 / (2 * np.pi * np.sqrt(S_det))) * np.exp(exponent)

# Compute total probability  $P(x)$ 
def total_prob(likelihoods, priors):
    return np.dot(likelihoods, priors)

# Compute posterior probabilities for point x
def compute_posteriors(x, means, S_inv, S_det, priors):
    likelihoods = np.array([gaussian_prob(x, m, S_inv, S_det) for m in means])
    total_probability = total_prob(likelihoods, priors)
    return (likelihoods * priors) / total_probability

# Classify a point x based on maximum posterior probability
def classify_point(posteriors):
    return np.argmax(posteriors), posteriors

# Decision boundaries for grid points
def decision_boundaries_grid(x1, x2, means, S_inv, S_det, priors):
    flat_grid = np.c_[x1.ravel(), x2.ravel()]
    posteriors = np.array([compute_posteriors(point, means, S_inv, S_det, priors) for point in flat_grid])
    return posteriors.argmax(axis=1).reshape(x1.shape), posteriors
```

```

# Classification of x = [3, 25]
x = np.array([3, 5])
likelihoods = np.array([gaussian_prob(x, m, S_inv, S_det) for m in means])
total_probability = total_prob(likelihoods, priors)
posteriors = compute_posteriors(x, means, S_inv, S_det, priors)
class_idx, posteriors = classify_point(posteriors)
print("\nLikelihoods for x =", x, ": P[x | wi] =", [f"{float(l):.4f}" for l in likelihoods])
print("Total probability for x =", x, ": P(x) =", f"{float(total_probability):.4f}")
print("Posterior probabilities for x =", x, ": P[wi|x] =", [f"{float(p):.4f}" for p in posteriors], "\n")
print("Point x =", x, "is classified in class", class_idx + 1, "\n")

# Create a mesh grid for plotting decision boundaries
x_min, x_max = -1, 10
y_min, y_max = -6, 11
x1, x2 = np.meshgrid(np.linspace(x_min, x_max, 100), np.linspace(y_min, y_max, 100))
Z, posteriors_grid = decision_boundaries_grid(x1, x2, means, S_inv, S_det, priors)

colors = ['red', 'blue', 'green']

# Plot pairwise decision boundaries
plt.figure(figsize=(15, 5))
titles = ["Class  $\omega_1$  vs  $\omega_2$ ", "Class  $\omega_2$  vs  $\omega_3$ ", "Class  $\omega_3$  vs  $\omega_1$ "]
for i, (w_i, w_j) in enumerate([(0, 1), (1, 2), (2, 0)]):
    Zij = (posteriors_grid[:, w_i] > posteriors_grid[:, w_j]).reshape(x1.shape)

    plt.subplot(1, 3, i + 1)
    plt.contourf(x1, x2, Zij, levels=[-0.5, 0.5, 1.5], colors=[colors[w_j], colors[w_i]], alpha=0.2)
    plt.contour(x1, x2, Zij, levels=[0], colors='black', linewidths=1)
    plt.scatter(*zip(*means), marker='x', color='black', label="Class Centers")
    plt.title(titles[i])
    plt.xlabel("X1")
    plt.ylabel("X2")

contour_legend = [Patch(color=colors[i], label=f"Class  $\omega_{i + 1}$ ") for i in range(len(colors))]

plt.tight_layout()
plt.legend(handles=contour_legend, loc="upper right", title="Classes")
plt.show()

```

```

plt.figure(figsize=(10, 8))

# Generate random points from each class distribution
n_points = 500
class_points = [np.random.multivariate_normal(m, S, n_points) for m in means]

# Plot the points from each class
for i, points in enumerate(class_points):
    plt.scatter(points[:, 0], points[:, 1], color=colors[i], label=f"Points of  $\omega_{i+1}$ ")

for i, (w_i, w_j) in enumerate([(0, 1), (1, 2), (2, 0)]):
    Zij = (posteriors_grid[:, w_i] > posteriors_grid[:, w_j]).reshape(x1.shape)
    plt.contour(x1, x2, Zij, levels=[0], colors='black', linewidths=2)

plt.contourf(x1, x2, Z, levels=[-1, 0.5, 1.5, 3], colors=colors, alpha=0.2)
plt.scatter(*zip(*means), marker='x', color='black', label="Class Centers")
plt.title("Combined Decision Boundaries and Class Centers")
plt.xlabel("X1")
plt.ylabel("X2")
plt.legend()
plt.show()

# Generate random points from class 2 for misclassification probability calculation
n_samples = 10000
samples = np.random.multivariate_normal(m2, S, n_samples)

# Calculate misclassified count
posteriors = np.array([compute_posteriors(sample, means, S_inv, S_det, priors) for sample in samples])
predicted_classes = np.argmax(posteriors, axis=1)
misclassified_count = np.sum(predicted_classes != 1)

# Calculate misclassification probability
misclassification_probability = misclassified_count / n_samples

print("\nMisclassification probability when true class is  $\omega_2$  for", n_samples, "samples:",
      misclassification_probability, "\n")

```

Άσκηση1.4 (python code)

```
import numpy as np
import matplotlib.pyplot as plt
from itertools import product

# Calculate outputs and separate points into classes
input_values = np.array([0, 1, 2])
points = {0: [], 1: [], 2: []}
for x1 in input_values:
    for x2 in input_values:
        y = (x1 + x2) % 3
        points[y].append((x1, x2))

# Plot the points for each output class
colors = ['red', 'green', 'blue']
labels = ['y = 0', 'y = 1', 'y = 2']
plt.figure(figsize=(8, 6))
for y in range(len(colors)):
    coords = np.array(points[y])
    plt.scatter(coords[:, 0], coords[:, 1], color=colors[y], label=labels[y])

# Draw decision areas
x1_range = np.linspace(-0.5, 2.5, 100)
x2_range = np.linspace(-0.5, 2.5, 100)
X1, X2 = np.meshgrid(x1_range, x2_range)
Y = (X1 + X2) % 3
plt.contourf(X1, X2, Y, levels=[-0.5, 0.5, 1.5, 2.5, 3.5], colors=colors, alpha=0.3)

# Final plot
plt.xlim(-0.5, 2.5)
plt.ylim(-0.5, 2.5)
plt.xlabel('x1')
plt.ylabel('x2')
plt.title("Decision Areas for  $y = (x_1 + x_2) \bmod 3$ ")
plt.axhline(0, color='black', linewidth=0.5, ls='--')
plt.axvline(0, color='black', linewidth=0.5, ls='--')
plt.grid(color='gray', linestyle='--', linewidth=0.5)
plt.legend()
plt.show()
```

```

# Define activation function
def step_function(x):
    return np.where(x >= 0, 1, -1)

# Weight matrix for input-to-hidden layer
weights_x_h = np.array([
    [1, 1, 1, 1],
    [1, 1, 1, 1]
])

# Weight matrix for hidden-to-output layer
weights_h_y = np.array([
    [-1, 1, 0],
    [0, -1, 1],
    [1, 0, -1],
    [-1, 1, 0]
])

# Biases for hidden and output layers
b_h = np.array([-0.5, -1.5, -2.5, -3.5])
b_y = np.array([-0.5, 0.5, -0.5])

# Define the neural network function
def mlp(inputs):
    # Hidden layer calculations
    h_input = np.dot(inputs, weights_x_h) + b_h
    h_output = step_function(h_input)

    # Output layer calculations
    y_input = np.dot(h_output, weights_h_y) + b_y
    output = step_function(y_input)

    return output

verification = []
for x1 in input_values:
    for x2 in input_values:
        x = np.array([x1, x2])
        output = mlp(x)

```

```
y_pred = np.where(output == 1)[0]
y_mod = (x1 + x2) % 3
verification.append((x1, x2, y_mod, y_pred[0]))

print(f"\n{x1:^5} {x2:^5} {(x1+x2)%3:^10} {Predictiton:^10} {Result:^10}")
for x1, x2, y_mod, y_pred in verification:
    result = 'True' if y_pred == y_mod else 'False'
    print(f"{x1:^5} {x2:^5} {y_mod:^10} {y_pred:^10} {result :^10}")
```