

Μηχανική Μάθηση

2η σειρά ασκήσεων

Ελένη Νασοπούλου – 03121087

Όνοματεπώνυμο: Ελένη Νασοπούλου

AM: 03121087

Email address: eleni.nspl@gmail.com

Οι κώδικες των προγραμμάτων βρίσκονται στο [τέλος](#) της εργασίας.

Άσκηση 2.1 (Decision Trees – Random Forests)

Ακολουθούν τα χαρακτηριστικά X_1, X_2, X_3, X_4 καθώς και οι αντίστοιχες κλάσεις ταξινόμησης Y ενός συνόλου δεδομένων.

X_1	X_2	X_3	X_4	Y
1	1	0	0	1
1	1	0	1	1
0	0	1	0	1
0	1	1	1	1
1	0	0	0	1
1	0	1	1	-1
0	1	0	1	-1
1	1	1	1	-1
0	0	0	1	-1

Κώδικας προγράμματος

Ερώτημα α

Θα δημιουργήσουμε το δέντρο αποφάσεων που προκύπτει με την χρήση του κριτηρίου Gini.

Αρχικά, θα υπολογίσουμε το Gini για το Root και για κάθε χαρακτηριστικό μέσω του ακόλουθου τύπου:

$$\text{Gini}(D) = \sum_{i \in \text{labels}(D)} p_i(1 - p_i) = 1 - \sum_{i \in \text{labels}(D)} p_i^2$$

Root

$$|Y = 1| = 5, |Y = -1| = 4 \Rightarrow \text{Gini}(\text{Root}) = 1 - \left(\frac{5}{9}\right)^2 - \left(\frac{4}{9}\right)^2 = \frac{40}{81}$$

$$\text{Gini}(\text{Root}) = 0.4938$$

Χαρακτηριστικό X_1

$$|X_1 = 1, Y = 1| = 3, |X_1 = 1, Y = -1| = 2 \Rightarrow \text{Gini}(X_1 = 1) = 1 - \left(\frac{3}{5}\right)^2 - \left(\frac{2}{5}\right)^2 = \frac{12}{25}$$

$$|X_1 = 0, Y = 1| = 2, |X_1 = 0, Y = -1| = 2 \Rightarrow \text{Gini}(X_1 = 0) = 1 - \left(\frac{2}{4}\right)^2 - \left(\frac{2}{4}\right)^2 = \frac{1}{2}$$

$$\text{Gini}(X_1) = p(X_1 = 1) \cdot \text{Gini}(X_1 = 1) + p(X_1 = 0) \cdot \text{Gini}(X_1 = 0) = \frac{5}{9} * \frac{12}{25} + \frac{4}{9} * \frac{1}{2} = \frac{22}{45}$$

$$\text{Gini}(X_1) = 0.4889$$

Χαρακτηριστικό X_2

$$|X_2 = 1, Y = 1| = 3, |X_2 = 1, Y = -1| = 2 \Rightarrow \text{Gini}(X_2 = 1) = 1 - \left(\frac{3}{5}\right)^2 - \left(\frac{2}{5}\right)^2 = \frac{12}{25}$$

$$|X_2 = 0, Y = 1| = 2, |X_2 = 0, Y = -1| = 2 \Rightarrow \text{Gini}(X_2 = 0) = 1 - \left(\frac{2}{4}\right)^2 - \left(\frac{2}{4}\right)^2 = \frac{1}{2}$$

$$\text{Gini}(X_2) = p(X_2 = 1) \cdot \text{Gini}(X_2 = 1) + p(X_2 = 0) \cdot \text{Gini}(X_2 = 0) = \frac{5}{9} * \frac{12}{25} + \frac{4}{9} * \frac{1}{2} = \frac{22}{45}$$

$$\text{Gini}(X_2) = 0.4889$$

Χαρακτηριστικό X_3

$$|X_3 = 1, Y = 1| = 2, |X_3 = 1, Y = -1| = 2 \Rightarrow \text{Gini}(X_3 = 1) = 1 - \left(\frac{2}{4}\right)^2 - \left(\frac{2}{4}\right)^2 = \frac{1}{2}$$

$$|X_3 = 0, Y = 1| = 3, |X_3 = 0, Y = -1| = 2 \Rightarrow \text{Gini}(X_3 = 0) = 1 - \left(\frac{3}{5}\right)^2 - \left(\frac{2}{5}\right)^2 = \frac{12}{25}$$

$$\text{Gini}(X_3) = p(X_3 = 1) \cdot \text{Gini}(X_3 = 1) + p(X_3 = 0) \cdot \text{Gini}(X_3 = 0) = \frac{4}{9} * \frac{1}{2} + \frac{5}{9} * \frac{12}{25} = \frac{22}{45}$$

$$\text{Gini}(X_3) = 0.4889$$

Χαρακτηριστικό X_4

$$|X_4 = 1, Y = 1| = 2, |X_4 = 1, Y = -1| = 4 \Rightarrow \text{Gini}(X_4 = 1) = 1 - \left(\frac{2}{6}\right)^2 - \left(\frac{4}{6}\right)^2 = \frac{4}{9}$$

$$|X_4 = 0, Y = 1| = 3, |X_4 = 0, Y = -1| = 0 \Rightarrow \text{Gini}(X_4 = 0) = 1 - 1 - 0 = 0$$

$$\text{Gini}(X_4) = p(X_4 = 1) \cdot \text{Gini}(X_4 = 1) + p(X_4 = 0) \cdot \text{Gini}(X_4 = 0) = \frac{6}{9} * \frac{4}{9} + \frac{3}{9} * 0 = \frac{8}{27}$$

$$\text{Gini}(X_4) = 0.2963$$

```
Gini(Root): 0.4938
Gini(X1): 0.4889
Gini(X2): 0.4889
Gini(X3): 0.4889
Gini(X4): 0.2963
```

Στη συνέχεια, θα υπολογίσουμε το information gain για κάθε χαρακτηριστικό μέσω του ακόλουθου τύπου:

$$\text{ig}(X_i) = \text{Gini}(\text{Root}) - \text{Gini}(X_i)$$

$$\text{ig}(X_1) = \text{Gini}(\text{Root}) - \text{Gini}(X_1) = \frac{40}{81} - \frac{22}{45} = \frac{2}{405} = 0.0049$$

$$\text{ig}(X_2) = \text{Gini}(\text{Root}) - \text{Gini}(X_2) = \frac{40}{81} - \frac{22}{45} = \frac{2}{405} = 0.0049$$

$$\text{ig}(X_3) = \text{Gini}(\text{Root}) - \text{Gini}(X_3) = \frac{40}{81} - \frac{22}{45} = \frac{2}{405} = 0.0049$$

$$\text{ig}(X_4) = \text{Gini}(\text{Root}) - \text{Gini}(X_4) = \frac{40}{81} - \frac{8}{27} = \frac{16}{81} = 0.1975$$

```
Information Gain:
IG(X1): 0.0049
IG(X2): 0.0049
IG(X3): 0.0049
IG(X4): 0.1975
```

Παρατηρούμε ότι το χαρακτηριστικό X_4 έχει το μεγαλύτερο information gain, οπότε θα το επιλέξουμε ως ρίζα του decision tree.

Στο επόμενο επίπεδο του δέντρου:

Gini($X_4=0$): 0.0000
Gini($X_4=1$): 0.4444

Φύλλο $X_4 = 0$

Τα χαρακτηριστικά X_1, X_2, X_3 για $X_4 = 0$ καθώς και οι αντίστοιχες κλάσεις ταξινόμησης Y του συνόλου δεδομένων

X_1	X_2	X_3	Y
1	1	0	1
0	0	1	1
1	0	0	1

Παρατηρούμε ότι όλα τα δείγματα έχουν $\text{Gini}^{X_4=0}(X_i) = 0$ και ανήκουν στην κλάση $Y = 1$. Συνεπώς το φύλλο δεν χρειάζεται περεταίρω διάσπαση

Φύλλο $X_4 = 1$

Τα χαρακτηριστικά X_1, X_2, X_3 για $X_4 = 1$ καθώς και οι αντίστοιχες κλάσεις ταξινόμησης Y του συνόλου δεδομένων

X_1	X_2	X_3	Y
1	1	0	1
0	1	1	1
1	0	1	-1
0	1	0	-1
1	1	1	-1
0	0	0	-1

Φύλλο $X_4 = 1$ / Χαρακτηριστικό X_1

$$|X_1 = 1, Y = 1| = 1, |X_1 = 1, Y = -1| = 2 \Rightarrow \text{Gini}^{X_4=1}(X_1 = 1) = 1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2 = \frac{4}{9}$$

$$|X_1 = 0, Y = 1| = 1, |X_1 = 0, Y = -1| = 2 \Rightarrow \text{Gini}^{X_4=1}(X_1 = 0) = 1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2 = \frac{4}{9}$$

$$\text{Gini}^{X_4=1}(X_1) = p(X_1 = 1) \cdot \text{Gini}(X_1 = 1) + p(X_1 = 0) \cdot \text{Gini}(X_1 = 0) = \frac{3}{6} * \frac{4}{9} + \frac{3}{6} * \frac{4}{9} = \frac{4}{9}$$

$$\text{Gini}^{X_4=1}(X_1) = 0.4444$$

Φύλλο $X_4 = 1$ / Χαρακτηριστικό X_2

$$|X_2 = 1, Y = 1| = 2, |X_2 = 1, Y = -1| = 2 \Rightarrow \text{Gini}^{X_4=1}(X_2 = 1) = 1 - \left(\frac{2}{4}\right)^2 - \left(\frac{2}{4}\right)^2 = \frac{1}{2}$$

$$|X_2 = 0, Y = 1| = 0, |X_2 = 0, Y = -1| = 2 \Rightarrow \text{Gini}^{X_4=1}(X_2 = 0) = 1 - 1 - 0 = 0$$

$$\text{Gini}^{X_4=1}(X_2) = p(X_2 = 1) \cdot \text{Gini}(X_2 = 1) + p(X_2 = 0) \cdot \text{Gini}(X_2 = 0) = \frac{4}{6} * \frac{1}{2} + \frac{2}{6} * 0 = \frac{1}{3}$$

$$\text{Gini}^{X_4=1}(X_2) = 0.3333$$

Φύλλο $X_4 = 1$ / Χαρακτηριστικό X_3

$$|X_3 = 1, Y = 1| = 1, |X_3 = 1, Y = -1| = 2 \Rightarrow \text{Gini}^{X_4=1}(X_3 = 1) = 1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2 = \frac{4}{9}$$

$$|X_3 = 0, Y = 1| = 1, |X_3 = 0, Y = -1| = 2 \Rightarrow \text{Gini}^{X_4=1}(X_3 = 0) = 1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2 = \frac{4}{9}$$

$$\text{Gini}^{X_4=1}(X_3) = p(X_3 = 1) \cdot \text{Gini}(X_3 = 1) + p(X_3 = 0) \cdot \text{Gini}(X_3 = 0) = \frac{3}{6} * \frac{4}{9} + \frac{3}{6} * \frac{4}{9} = \frac{4}{9}$$

$$\text{Gini}^{X_4=1}(X_3) = 0.4444$$

```
Gini for branches under X4=1:
Gini(X4=1, X1): 0.4444
Gini(X4=1, X2): 0.3333
Gini(X4=1, X3): 0.4444
```

Στη συνέχεια, θα υπολογίσουμε το νέο information gain για κάθε χαρακτηριστικό μέσω του ακόλουθου τύπου:

$$ig^{X_4=1}(X_i) = \text{Gini}(X_4 = 1) - \text{Gini}^{X_4=1}(X_i)$$

$$ig^{X_4=1}(X_1) = \text{Gini}(X_4 = 1) - \text{Gini}^{X_4=1}(X_1) = \frac{4}{9} - \frac{4}{9} = 0$$

$$ig^{X_4=1}(X_2) = \text{Gini}(X_4 = 1) - \text{Gini}^{X_4=1}(X_2) = \frac{4}{9} - \frac{1}{3} = \frac{1}{9} = 0.1111$$

$$ig^{X_4=1}(X_3) = \text{Gini}(X_4 = 1) - \text{Gini}^{X_4=1}(X_3) = \frac{4}{9} - \frac{4}{9} = 0$$

```
Information Gain for branches under X4=1:
IG(X4=1, X1): 0.0000
IG(X4=1, X2): 0.1111
IG(X4=1, X3): 0.0000
```

Παρατηρούμε ότι το X_2 έχει το μεγαλύτερο information gain, συνεπώς θα το επιλέξουμε για περεταίρω διάσπαση.

Στο επόμενο επίπεδο του δέντρου:

```
Gini(X4=1, X2=0): 0.0000
Gini(X4=1, X2=1): 0.5000
```

Φύλλο $X_4 = 1, X_2 = 0$

Τα χαρακτηριστικά X_1, X_3 για $X_2 = 0, X_4 = 1$ καθώς και οι αντίστοιχες κλάσεις ταξινόμησης Y του συνόλου δεδομένων

X_1	X_3	Y
1	1	-1
0	0	-1

Παρατηρούμε ότι όλα τα δείγματα έχουν $\text{Gini}^{X_4=1, X_2=0}(X_i) = 0$ και ανήκουν στην κλάση $Y = -1$.

Συνεπώς το φύλλο δεν χρειάζεται περεταίρω διάσπαση.

Φύλλο $X_4 = 1, X_2 = 1$

Τα χαρακτηριστικά X_1, X_3 για $X_2 = 1, X_4 = 1$ καθώς και οι αντίστοιχες κλάσεις ταξινόμησης Y του συνόλου δεδομένων

X_1	X_3	Y
1	0	1
0	1	1
0	0	-1
1	1	-1

Φύλλο $X_4 = 1, X_2 = 1$ / Χαρακτηριστικό X_1

$$|X_1 = 1, Y = 1| = 1, |X_1 = 1, Y = -1| = 1 \Rightarrow \text{Gini}^{X_4=1, X_2=1}(X_1 = 1) = \frac{1}{2}$$

$$|X_1 = 0, Y = 1| = 1, |X_1 = 0, Y = -1| = 1 \Rightarrow \text{Gini}^{X_4=1, X_2=1}(X_1 = 0) = \frac{1}{2}$$

$$\text{Gini}^{X_4=1, X_2=1}(X_1) = p(X_1 = 1) \cdot \text{Gini}(X_1 = 1) + p(X_1 = 0) \cdot \text{Gini}(X_1 = 0) = \frac{1}{2}$$

$$\text{Gini}^{X_4=1, X_2=1}(X_1) = 0.5$$

Φύλλο $X_4 = 1, X_2 = 1$ / Χαρακτηριστικό X_3

$$|X_3 = 1, Y = 1| = 1, |X_3 = 1, Y = -1| = 1 \Rightarrow \text{Gini}^{X_4=1, X_2=1}(X_3 = 1) = \frac{1}{2}$$

$$|X_3 = 0, Y = 1| = 1, |X_3 = 0, Y = -1| = 1 \Rightarrow \text{Gini}^{X_4=1, X_2=1}(X_3 = 0) = \frac{1}{2}$$

$$\text{Gini}^{X_4=1, X_2=1}(X_3) = p(X_3 = 1) \cdot \text{Gini}(X_3 = 1) + p(X_3 = 0) \cdot \text{Gini}(X_3 = 0) = \frac{1}{2}$$

$$\text{Gini}^{X_4=1, X_2=1}(X_3) = 0.5$$

Final splits for $X_4=1, X_2=1$:
Gini($X_4=1, X_2=1, X_1$): 0.5000
Gini($X_4=1, X_2=1, X_3$): 0.5000

Στη συνέχεια, θα υπολογίσουμε το νέο information gain για κάθε χαρακτηριστικό μέσω του ακόλουθου τύπου:

$$\text{ig}^{X_4=1, X_2=1}(X_i) = \text{Gini}^{X_4=1}(X_2 = 1) - \text{Gini}^{X_4=1, X_2=1}(X_i)$$

$$\text{ig}^{X_4=1, X_2=1}(X_1) = \text{Gini}^{X_4=1}(X_2 = 1) - \text{Gini}^{X_4=1, X_2=1}(X_1) = \frac{1}{2} - \frac{1}{2} = 0$$

$$\text{ig}^{X_4=1, X_2=1}(X_3) = \text{Gini}^{X_4=1}(X_2 = 1) - \text{Gini}^{X_4=1, X_2=1}(X_3) = \frac{1}{2} - \frac{1}{2} = 0$$

Παρατηρούμε ότι και τα δύο χαρακτηριστικά έχουν το ίδιο information gain, συνεπώς θα επιλέξουμε το X_1 επειδή είναι αλφαριθμητικά μεγαλύτερο.

Φύλλο $X_4 = 1, X_2 = 1, X_1 = 1$

Το χαρακτηριστικό X_3 για $X_2 = 1, X_4 = 1, X_1 = 1$ καθώς και οι αντίστοιχες κλάσεις ταξινόμησης Y του συνόλου δεδομένων

X_3	Y
0	1
1	-1

Τα δεδομένα χωρίζονται σε $Y = 1, Y = -1$ συνεπώς ο κάθε κόμβος είναι τερματικός.


Φύλλο $X_4 = 1, X_2 = 1, X_1 = 0$

Το χαρακτηριστικό X_3 για $X_2 = 1, X_4 = 1, X_1 = 0$ καθώς και οι αντίστοιχες κλάσεις ταξινόμησης Y του συνόλου δεδομένων

X_3	Y
1	1
0	-1

Τα δεδομένα χωρίζονται σε $Y = 1, Y = -1$ συνεπώς ο κάθε κόμβος είναι τερματικός.

Το αντίστοιχα decision tree με ακρίβεια 1:




Ερώτημα β

Παρατηρούμε ότι: $Y = X_1 \text{ XOR } X_3$

X_1	X_3	Y
1	0	1
1	0	1
0	1	1
0	1	1
1	0	1
1	1	-1
0	0	-1
1	1	-1
0	0	-1

Συνεπώς, το νέο decision tree με ακρίβεια 1 είναι το εξής:



Ερώτημα γ

1ο δέντρο:

Παρατηρήσεις για εκπαίδευση:

X_1	X_2	X_3	X_4	Y
1	1	0	0	1
0	1	1	1	1
0	1	0	1	-1

Αρχικά, θα υπολογίσουμε το Gini για το Root και για κάθε χαρακτηριστικό μέσω του ακόλουθου τύπου:

$$\text{Gini}(D) = \sum_{i \in \text{labels}(D)} p_i(1 - p_i) = 1 - \sum_{i \in \text{labels}(D)} p_i^2$$

Root

$$|Y = 1| = 2, |Y = -1| = 1 \Rightarrow \text{Gini}(\text{Root}) = 1 - \left(\frac{2}{3}\right)^2 - \left(\frac{1}{3}\right)^2 = \frac{4}{9}$$

$$\text{Gini}(\text{Root}) = 0.4444$$

Χαρακτηριστικό X_1

$$|X_1 = 1, Y = 1| = 1, |X_1 = 1, Y = -1| = 0 \Rightarrow \text{Gini}(X_1 = 1) = 1 - 1 - 0 = 0$$

$$|X_1 = 0, Y = 1| = 1, |X_1 = 0, Y = -1| = 1 \Rightarrow \text{Gini}(X_1 = 0) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = \frac{1}{2}$$

$$\text{Gini}(X_1) = p(X_1 = 1) \cdot \text{Gini}(X_1 = 1) + p(X_1 = 0) \cdot \text{Gini}(X_1 = 0) = \frac{1}{3} * 0 + \frac{2}{3} * \frac{1}{2} = \frac{1}{3}$$

$$\text{Gini}(X_1) = 0.3333$$

Χαρακτηριστικό X_2

$$|X_2 = 1, Y = 1| = 2, |X_2 = 1, Y = -1| = 1 \Rightarrow \text{Gini}(X_2 = 1) = 1 - \left(\frac{2}{3}\right)^2 - \left(\frac{1}{3}\right)^2 = \frac{4}{9}$$

$$|X_2 = 0, Y = 1| = 0, |X_2 = 0, Y = -1| = 0 \Rightarrow \text{Gini}(X_2 = 0) = 1 - 0 - 0 = 1$$

$$\text{Gini}(X_2) = p(X_2 = 1) \cdot \text{Gini}(X_2 = 1) + p(X_2 = 0) \cdot \text{Gini}(X_2 = 0) = 1 * \frac{4}{9} + 0 * 1 = \frac{4}{9}$$

$$\text{Gini}(X_2) = 0.4444$$

Χαρακτηριστικό X_3

$$|X_3 = 1, Y = 1| = 1, |X_3 = 1, Y = -1| = 0 \Rightarrow \text{Gini}(X_3 = 1) = 1 - 1 - 0 = 0$$

$$|X_3 = 0, Y = 1| = 1, |X_3 = 0, Y = -1| = 1 \Rightarrow \text{Gini}(X_3 = 0) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = \frac{1}{2}$$

$$\text{Gini}(X_3) = p(X_3 = 1) \cdot \text{Gini}(X_3 = 1) + p(X_3 = 0) \cdot \text{Gini}(X_3 = 0) = \frac{1}{3} * 0 + \frac{2}{3} * \frac{1}{2} = \frac{1}{3}$$

$$\text{Gini}(X_3) = 0.3333$$

Χαρακτηριστικό X_4

$$|X_4 = 1, Y = 1| = 1, |X_4 = 1, Y = -1| = 1 \Rightarrow \text{Gini}(X_4 = 1) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = \frac{1}{2}$$

$$|X_4 = 0, Y = 1| = 1, |X_4 = 0, Y = -1| = 0 \Rightarrow \text{Gini}(X_4 = 0) = 1 - 1 - 0 = 0$$

$$\text{Gini}(X_4) = p(X_4 = 1) \cdot \text{Gini}(X_4 = 1) + p(X_4 = 0) \cdot \text{Gini}(X_4 = 0) = \frac{2}{3} * \frac{1}{2} + \frac{1}{3} * 0 = \frac{1}{3}$$

$$\text{Gini}(X_4) = 0.3333$$

Στη συνέχεια, θα υπολογίσουμε το information gain για κάθε χαρακτηριστικό μέσω του ακόλουθου τύπου:

$$ig(X_i) = \text{Gini}(\text{Root}) - \text{Gini}(X_i)$$

$$ig(X_1) = \text{Gini}(\text{Root}) - \text{Gini}(X_1) = \frac{4}{9} - \frac{1}{3} = \frac{1}{9} = 0.1111$$

$$ig(X_2) = \text{Gini}(\text{Root}) - \text{Gini}(X_2) = \frac{4}{9} - \frac{4}{9} = 0$$

$$ig(X_3) = \text{Gini}(\text{Root}) - \text{Gini}(X_3) = \frac{4}{9} - \frac{1}{3} = \frac{1}{9} = 0.1111$$

$$ig(X_4) = \text{Gini}(\text{Root}) - \text{Gini}(X_4) = \frac{4}{9} - \frac{1}{3} = \frac{1}{9} = 0.1111$$

Παρατηρούμε ότι και τα χαρακτηριστικά X_1, X_3, X_4 έχουν το ίδιο information gain, συνεπώς θα επιλέξουμε το X_1 ως ρίζα του decision tree επειδή είναι αλφαβητικά μεγαλύτερο.

Στο επόμενο επίπεδο του δέντρου:

Φύλλο $X_1 = 1$

Τα χαρακτηριστικά X_2, X_3, X_4 για $X_1 = 1$ καθώς και οι αντίστοιχες κλάσεις ταξινόμησης Y του συνόλου δεδομένων

X_2	X_3	X_4	Y
1	0	0	1

Παρατηρούμε ότι όλα τα δείγματα έχουν $\text{Gini}^{X_1=1}(X_i) = 0$ και ανήκουν στην κλάση $Y = 1$. Συνεπώς το φύλλο δεν χρειάζεται περεταίρω διάσπαση.

Φύλλο $X_1 = 0$

Τα χαρακτηριστικά X_2, X_3, X_4 για $X_1 = 0$ καθώς και οι αντίστοιχες κλάσεις ταξινόμησης Y του συνόλου δεδομένων

X_2	X_3	X_4	Y
1	1	1	1
1	0	1	-1

Φύλλο $X_1 = 0$ / Χαρακτηριστικό X_2

$$|X_2 = 1, Y = 1| = 1, |X_2 = 1, Y = -1| = 1 \Rightarrow \text{Gini}^{X_1=0}(X_2 = 1) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = \frac{1}{2}$$

$$|X_2 = 0, Y = 1| = 0, |X_2 = 0, Y = -1| = 0 \Rightarrow \text{Gini}^{X_1=0}(X_2 = 0) = 1 - 0 - 0 = 1$$

$$\text{Gini}^{X_1=0}(X_2) = p(X_2 = 1) \cdot \text{Gini}(X_2 = 1) + p(X_2 = 0) \cdot \text{Gini}(X_2 = 0) = 1 * \frac{1}{2} + 0 * 1 = \frac{1}{2}$$

$$\text{Gini}^{X_1=0}(X_2) = 0.5$$

Φύλλο $X_1 = 0$ / Χαρακτηριστικό X_3

$$|X_3 = 1, Y = 1| = 1, |X_3 = 1, Y = -1| = 0 \Rightarrow \text{Gini}^{X_1=0}(X_3 = 1) = 1 - 1 - 0 = 0$$

$$|X_3 = 0, Y = 1| = 0, |X_3 = 0, Y = -1| = 1 \Rightarrow \text{Gini}^{X_1=0}(X_3 = 0) = 1 - 0 - 1 = 0$$

$$\text{Gini}^{X_1=0}(X_3) = p(X_3 = 1) \cdot \text{Gini}(X_3 = 1) + p(X_3 = 0) \cdot \text{Gini}(X_3 = 0) = \frac{1}{2} * 0 + \frac{1}{2} * 0 = 0$$

$$\text{Gini}^{X_1=0}(X_3) = 0$$

Φύλλο $X_1 = 0$ / Χαρακτηριστικό X_4

$$|X_4 = 1, Y = 1| = 1, |X_4 = 1, Y = -1| = 1 \Rightarrow \text{Gini}^{X_1=0}(X_4 = 1) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = \frac{1}{2}$$

$$|X_4 = 0, Y = 1| = 0, |X_4 = 0, Y = -1| = 0 \Rightarrow \text{Gini}^{X_1=0}(X_4 = 0) = 1 - 0 - 0 = 1$$

$$\text{Gini}^{X_1=0}(X_4) = p(X_4 = 1) \cdot \text{Gini}(X_4 = 1) + p(X_4 = 0) \cdot \text{Gini}(X_4 = 0) = 1 \cdot \frac{1}{2} + 0 \cdot 1 = \frac{1}{2}$$

$$\text{Gini}^{X_1=0}(X_4) = 0.5$$

Στη συνέχεια, θα υπολογίσουμε το νέο information gain για κάθε χαρακτηριστικό μέσω του ακόλουθου τύπου:

$$\text{ig}^{X_1=0}(X_i) = \text{Gini}(X_1 = 0) - \text{Gini}^{X_1=0}(X_i)$$

$$\text{ig}^{X_1=0}(X_2) = \text{Gini}(X_1 = 0) - \text{Gini}^{X_1=0}(X_2) = \frac{1}{2} - \frac{1}{2} = 0$$

$$\text{ig}^{X_1=0}(X_3) = \text{Gini}(X_1 = 0) - \text{Gini}^{X_1=0}(X_3) = \frac{1}{2} - 0 = \frac{1}{2} = 0.5$$

$$\text{ig}^{X_1=0}(X_4) = \text{Gini}(X_1 = 0) - \text{Gini}^{X_1=0}(X_4) = \frac{1}{2} - \frac{1}{2} = 0$$

Παρατηρούμε ότι το X_3 έχει το μεγαλύτερο information gain, συνεπώς θα το επιλέξουμε για περεταίρω διάσπαση.

Στο επόμενο επίπεδο του δέντρου:

Φύλλο $X_1 = 0, X_3 = 0$

Τα χαρακτηριστικά X_2, X_4 για $X_1 = 0, X_3 = 0$ καθώς και οι αντίστοιχες κλάσεις ταξινόμησης Y του συνόλου δεδομένων

X_2	X_4	Y
1	1	-1

Παρατηρούμε ότι όλα τα δείγματα έχουν $\text{Gini}^{X_1=0, X_3=0}(X_i) = 0$ και ανήκουν στην κλάση $Y = -1$.

Συνεπώς το φύλλο δεν χρειάζεται περεταίρω διάσπαση.


Φύλλο $X_1 = 0, X_3 = 1$

Τα χαρακτηριστικά X_2, X_4 για $X_1 = 0, X_3 = 1$ καθώς και οι αντίστοιχες κλάσεις ταξινόμησης Y του συνόλου δεδομένων

X_2	X_4	Y
1	1	1

Παρατηρούμε ότι όλα τα δείγματα έχουν $\text{Gini}^{X_1=0, X_3=1}(X_i) = 0$ και ανήκουν στην κλάση $Y = 1$. Συνεπώς το φύλλο δεν χρειάζεται περεταίρω διάσπαση.

Έτσι, έχουμε δέντρο 1:



2ο δέντρο:

Παρατηρήσεις για εκπαίδευση:

X_1	X_2	X_3	X_4	Y
1	1	0	1	1
1	0	0	0	1
1	1	1	1	-1

Αρχικά, θα υπολογίσουμε το Gini για το Root και για κάθε χαρακτηριστικό μέσω του ακόλουθου τύπου:

$$\text{Gini}(D) = \sum_{i \in \text{labels}(D)} p_i(1 - p_i) = 1 - \sum_{i \in \text{labels}(D)} p_i^2$$

Root

$$|Y = 1| = 2, |Y = -1| = 1 \Rightarrow \text{Gini}(\text{Root}) = 1 - \left(\frac{2}{3}\right)^2 - \left(\frac{1}{3}\right)^2 = \frac{4}{9}$$

$$\text{Gini}(\text{Root}) = 0.4444$$

Χαρακτηριστικό X_1

$$|X_1 = 1, Y = 1| = 2, |X_1 = 1, Y = -1| = 1 \Rightarrow \text{Gini}(X_1 = 1) = 1 - \left(\frac{2}{3}\right)^2 - \left(\frac{1}{3}\right)^2 = \frac{4}{9}$$

$$|X_1 = 0, Y = 1| = 0, |X_1 = 0, Y = -1| = 0 \Rightarrow \text{Gini}(X_1 = 0) = 1 - 0 - 0 = 1$$

$$\text{Gini}(X_1) = p(X_1 = 1) \cdot \text{Gini}(X_1 = 1) + p(X_1 = 0) \cdot \text{Gini}(X_1 = 0) = 1 * \frac{4}{9} + 0 * 1 = \frac{4}{9}$$

$$\text{Gini}(X_1) = 0.4444$$

Χαρακτηριστικό X_2

$$|X_2 = 1, Y = 1| = 1, |X_2 = 1, Y = -1| = 1 \Rightarrow \text{Gini}(X_2 = 1) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = \frac{1}{2}$$

$$|X_2 = 0, Y = 1| = 1, |X_2 = 0, Y = -1| = 0 \Rightarrow \text{Gini}(X_2 = 0) = 1 - 1 - 0 = 0$$

$$\text{Gini}(X_2) = p(X_2 = 1) \cdot \text{Gini}(X_2 = 1) + p(X_2 = 0) \cdot \text{Gini}(X_2 = 0) = \frac{2}{3} * \frac{1}{2} + \frac{1}{3} * 0 = \frac{1}{3}$$

$$\text{Gini}(X_2) = 0.3333$$

Χαρακτηριστικό X_3

$$|X_3 = 1, Y = 1| = 0, |X_3 = 1, Y = -1| = 1 \Rightarrow \text{Gini}(X_3 = 1) = 1 - 0 - 1 = 0$$

$$|X_3 = 0, Y = 1| = 2, |X_3 = 0, Y = -1| = 0 \Rightarrow \text{Gini}(X_3 = 0) = 1 - 1 - 0 = 0$$

$$\text{Gini}(X_3) = p(X_3 = 1) \cdot \text{Gini}(X_3 = 1) + p(X_3 = 0) \cdot \text{Gini}(X_3 = 0) = \frac{1}{3} * 0 + \frac{2}{3} * 0 = 0$$

$$\text{Gini}(X_3) = 0$$

Χαρακτηριστικό X_4

$$|X_4 = 1, Y = 1| = 1, |X_4 = 1, Y = -1| = 1 \Rightarrow \text{Gini}(X_4 = 1) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = \frac{1}{2}$$

$$|X_4 = 0, Y = 1| = 1, |X_4 = 0, Y = -1| = 0 \Rightarrow \text{Gini}(X_4 = 0) = 1 - 1 - 0 = 0$$

$$\text{Gini}(X_4) = p(X_4 = 1) \cdot \text{Gini}(X_4 = 1) + p(X_4 = 0) \cdot \text{Gini}(X_4 = 0) = \frac{2}{3} * \frac{1}{2} + \frac{1}{3} * 0 = \frac{1}{3}$$

$$\text{Gini}(X_4) = 0.3333$$

Στη συνέχεια, θα υπολογίσουμε το information gain για κάθε χαρακτηριστικό μέσω του ακόλουθου τύπου:

$$\text{ig}(X_i) = \text{Gini}(\text{Root}) - \text{Gini}(X_i)$$

$$\begin{aligned} \text{ig}(X_1) &= \text{Gini}(\text{Root}) - \text{Gini}(X_1) = \frac{4}{9} - \frac{4}{9} = 0 \\ \text{ig}(X_2) &= \text{Gini}(\text{Root}) - \text{Gini}(X_2) = \frac{4}{9} - \frac{1}{3} = \frac{1}{9} = 0.1111 \\ \text{ig}(X_3) &= \text{Gini}(\text{Root}) - \text{Gini}(X_3) = \frac{4}{9} - 0 = \frac{4}{9} = 0.4444 \\ \text{ig}(X_4) &= \text{Gini}(\text{Root}) - \text{Gini}(X_4) = \frac{4}{9} - \frac{1}{3} = \frac{1}{9} = 0.1111 \end{aligned}$$

Παρατηρούμε ότι και το χαρακτηριστικό X_3 έχει το μεγαλύτερο information gain, συνεπώς θα το επιλέξουμε ως ρίζα του decision tree.

Στο επόμενο επίπεδο του δέντρου:

Φύλλο $X_3 = 1$

Τα χαρακτηριστικά X_1, X_2, X_4 για $X_3 = 1$ καθώς και οι αντίστοιχες κλάσεις ταξινόμησης Y του συνόλου δεδομένων

X_1	X_2	X_4	Y
1	1	1	-1

Παρατηρούμε ότι όλα τα δείγματα έχουν $\text{Gini}^{X_3=1}(X_i) = 0$ και ανήκουν στην κλάση $Y = -1$. Συνεπώς το φύλλο δεν χρειάζεται περεταίρω διάσπαση.


Φύλλο $X_3 = 0$

Τα χαρακτηριστικά X_1, X_2, X_4 για $X_3 = 0$ καθώς και οι αντίστοιχες κλάσεις ταξινόμησης Y του συνόλου δεδομένων

X_1	X_2	X_4	Y
1	1	1	1
1	0	0	1

Παρατηρούμε ότι όλα τα δείγματα έχουν $\text{Gini}^{X_3=0}(X_i) = 0$ και ανήκουν στην κλάση $Y = 1$. Συνεπώς το φύλλο δεν χρειάζεται περεταίρω διάσπαση.

Έτσι, έχουμε δέντρο 2:



3ο δέντρο:

Παρατηρήσεις για εκπαίδευση:

X_1	X_2	X_3	X_4	Y
0	0	1	0	1
1	0	1	1	-1

0	0	0	1	-1
---	---	---	---	----

Αρχικά, θα υπολογίσουμε το Gini για το Root και για κάθε χαρακτηριστικό μέσω του ακόλουθου τύπου:

$$\text{Gini}(D) = \sum_{i \in \text{labels}(D)} p_i(1 - p_i) = 1 - \sum_{i \in \text{labels}(D)} p_i^2$$

Root

$$|Y = 1| = 1, |Y = -1| = 2 \Rightarrow \text{Gini}(\text{Root}) = 1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2 = \frac{4}{9}$$

$$\text{Gini}(\text{Root}) = 0.4444$$

Χαρακτηριστικό X_1

$$|X_1 = 1, Y = 1| = 0, |X_1 = 1, Y = -1| = 1 \Rightarrow \text{Gini}(X_1 = 1) = 1 - 0 - 1 = 0$$

$$|X_1 = 0, Y = 1| = 1, |X_1 = 0, Y = -1| = 1 \Rightarrow \text{Gini}(X_1 = 0) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = \frac{1}{2}$$

$$\text{Gini}(X_1) = p(X_1 = 1) \cdot \text{Gini}(X_1 = 1) + p(X_1 = 0) \cdot \text{Gini}(X_1 = 0) = \frac{1}{3} * 0 + \frac{2}{3} * \frac{1}{2} = \frac{1}{3}$$

$$\text{Gini}(X_1) = 0.3333$$

Χαρακτηριστικό X_2

$$|X_2 = 1, Y = 1| = 0, |X_2 = 1, Y = -1| = 0 \Rightarrow \text{Gini}(X_2 = 1) = 1 - 0 - 0 = 1$$

$$|X_2 = 0, Y = 1| = 1, |X_2 = 0, Y = -1| = 2 \Rightarrow \text{Gini}(X_2 = 0) = 1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2 = \frac{4}{9}$$

$$\text{Gini}(X_2) = p(X_2 = 1) \cdot \text{Gini}(X_2 = 1) + p(X_2 = 0) \cdot \text{Gini}(X_2 = 0) = 0 * 1 + 1 * \frac{4}{9} = \frac{4}{9}$$

$$\text{Gini}(X_2) = 0.4444$$

Χαρακτηριστικό X_3

$$|X_3 = 1, Y = 1| = 1, |X_3 = 1, Y = -1| = 1 \Rightarrow \text{Gini}(X_3 = 1) = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = \frac{1}{2}$$

$$|X_3 = 0, Y = 1| = 0, |X_3 = 0, Y = -1| = 1 \Rightarrow \text{Gini}(X_3 = 0) = 1 - 0 - 1 = 0$$

$$\text{Gini}(X_3) = p(X_3 = 1) \cdot \text{Gini}(X_3 = 1) + p(X_3 = 0) \cdot \text{Gini}(X_3 = 0) = \frac{2}{3} * \frac{1}{2} + \frac{1}{3} * 0 = \frac{1}{3}$$

$$\text{Gini}(X_3) = 0.3333$$

Χαρακτηριστικό X_4

$$|X_4 = 1, Y = 1| = 0, |X_4 = 1, Y = -1| = 2 \Rightarrow \text{Gini}(X_4 = 1) = 1 - 0 - 1 = 0$$

$$|X_4 = 0, Y = 1| = 1, |X_4 = 0, Y = -1| = 0 \Rightarrow \text{Gini}(X_4 = 0) = 1 - 1 - 0 = 0$$

$$\text{Gini}(X_4) = p(X_4 = 1) \cdot \text{Gini}(X_4 = 1) + p(X_4 = 0) \cdot \text{Gini}(X_4 = 0) = \frac{2}{3} * 0 + \frac{1}{3} * 0 = 0$$

$$\text{Gini}(X_4) = 0$$

Στη συνέχεια, θα υπολογίσουμε το information gain για κάθε χαρακτηριστικό μέσω του ακόλουθου τύπου:

$$\text{ig}(X_i) = \text{Gini}(\text{Root}) - \text{Gini}(X_i)$$

$$\text{ig}(X_1) = \text{Gini}(\text{Root}) - \text{Gini}(X_1) = \frac{4}{9} - \frac{1}{3} = \frac{1}{9} = 0.1111$$

$$\text{ig}(X_2) = \text{Gini}(\text{Root}) - \text{Gini}(X_2) = \frac{4}{9} - \frac{4}{9} = 0$$

$$\text{ig}(X_3) = \text{Gini}(\text{Root}) - \text{Gini}(X_3) = \frac{4}{9} - \frac{1}{3} = \frac{1}{9} = 0.1111$$

$$\text{ig}(X_4) = \text{Gini}(\text{Root}) - \text{Gini}(X_4) = \frac{4}{9} - 0 = \frac{4}{9} = 0.4444$$

Παρατηρούμε ότι και το χαρακτηριστικό X_4 έχει το μεγαλύτερο information gain, συνεπώς θα το επιλέξουμε ως ρίζα του decision tree.

Στο επόμενο επίπεδο του δέντρου:

Φύλλο $X_4 = 1$

Τα χαρακτηριστικά X_1, X_2, X_3 για $X_4 = 1$ καθώς και οι αντίστοιχες κλάσεις ταξινόμησης Y του συνόλου δεδομένων

X_1	X_2	X_3	Y
1	0	1	-1
0	0	0	-1

Παρατηρούμε ότι όλα τα δείγματα έχουν $\text{Gini}^{X_4=1}(X_i) = 0$ και ανήκουν στην κλάση $Y = -1$. Συνεπώς το φύλλο δεν χρειάζεται περεταίρω διάσπαση.


Φύλλο $X_4 = 0$

Τα χαρακτηριστικά X_1, X_2, X_3 για $X_4 = 0$ καθώς και οι αντίστοιχες κλάσεις ταξινόμησης Y του συνόλου δεδομένων


X_1	X_2	X_3	Y
0	0	1	1

Παρατηρούμε ότι όλα τα δείγματα έχουν $\text{Gini}^{X_4=0}(X_i) = 0$ και ανήκουν στην κλάση $Y = 1$. Συνεπώς το φύλλο δεν χρειάζεται περεταίρω διάσπαση.

Έτσι, έχουμε δέντρο 3:



Συνολικά έχουμε το ακόλουθο random forest:



Άσκηση 2.2 (Εφαρμογή του k-Means σε συνθετικά και πραγματικά δεδομένα)

Συνθετικά δεδομένα:

Σύνολο προτύπων στο $\mathbb{R}^2$: $X = \{(2, 3), (3, 2), (1, 2), (4, 5), (5, 4), (3, 4), (6, 4), (6, 5)\}$.

Κώδικας προγράμματος

Ερώτημα α

Θα εφαρμόσουμε τον k-Means αλγόριθμο στα δεδομένα X για $m = 2$ κλάσεις και αρχικοποίηση στα κέντρα $C_1 = (3, 3)$ και $C_2 = (4, 4)$.

Αρχικοποίηση

Κέντρα: $C_1^{(0)} = (3, 3)$ και $C_2^{(0)} = (4, 4)$

Επανάληψη 1:

Υπολογίζουμε την ευκλείδεια απόσταση του κάθε σημείου από το κάθε κέντρο και το ταξινομούμε στη συστάδα με την μικρότερη απόσταση.

$$d(x, C) = \sqrt{(x_1 - c_1)^2 + (x_2 - c_2)^2}$$

Iteration 1:					
Centroids: [(3, 3), (4, 4)]					
Distances and Assigned Clusters:					
		C1	C2	Assigned Cluster	
Point 1 ((2, 3))	1.000000	2.236068		C1	
Point 2 ((3, 2))	1.000000	2.236068		C1	
Point 3 ((1, 2))	2.236068	3.605551		C1	
Point 4 ((4, 5))	2.236068	1.000000		C2	
Point 5 ((5, 4))	2.236068	1.000000		C2	
Point 6 ((3, 4))	1.000000	1.000000		C1	
Point 7 ((6, 4))	3.162278	2.000000		C2	
Point 8 ((6, 5))	3.605551	2.236068		C2	

Στο τέλος της 1ης επανάληψης:

Σημεία στην C_1 : {(2,3), (3,2), (1,2), (3,4)}

Σημεία στην C_2 : {(4,5), (5,4), (6,4), (6,5)}

Επαναπροσδιορίζουμε τα κέντρα των κλάσεων από τους μέσους όρους των σημείων τους.

$$C_i = \frac{1}{|X_i|} \sum_{x \in X_i} x$$

$$C_1^{(1)} = \frac{1}{4}(2 + 3 + 1 + 3, 3 + 2 + 2 + 4) = \left(\frac{9}{4}, \frac{11}{4}\right) = (2.25, 2.75)$$

$$C_2^{(1)} = \frac{1}{4}(4 + 5 + 6 + 6, 5 + 4 + 4 + 5) = \left(\frac{21}{4}, \frac{9}{2}\right) = (5.25, 4.5)$$

Τα κέντρα αλλάξανε, οπότε προχωράμε στην επόμενη επανάληψη.

Επανάληψη 2:

Υπολογίζουμε την ευκλείδεια απόσταση του κάθε σημείου από το κάθε κέντρο και το ταξινομούμε στη συστάδα με την μικρότερη απόσταση.

$$d(x, C) = \sqrt{(x_1 - c_1)^2 + (x_2 - c_2)^2}$$

Iteration 2:					
Centroids: [(2.25, 2.75), (5.25, 4.5)]					
Distances and Assigned Clusters:					
		C1	C2	Assigned Cluster	
Point 1 ((2, 3))	0.353553	3.579455		C1	
Point 2 ((3, 2))	1.060660	3.363406		C1	
Point 3 ((1, 2))	1.457738	4.930771		C1	
Point 4 ((4, 5))	2.850439	1.346291		C2	
Point 5 ((5, 4))	3.020761	0.559017		C2	
Point 6 ((3, 4))	1.457738	2.304886		C1	
Point 7 ((6, 4))	3.952847	0.901388		C2	
Point 8 ((6, 5))	4.373214	0.901388		C2	

Στο τέλος της 2ης επανάληψης:

Σημεία στην C_1 : {(2,3), (3,2), (1,2), (3,4)}

Σημεία στην C_2 : {(4,5), (5,4), (6,4), (6,5)}

Επαναπροσδιορίζουμε τα κέντρα των κλάσεων από τους μέσους όρους των σημείων τους.

$$C_i = \frac{1}{|X_i|} \sum_{x \in X_i} x$$

$$C_1^{(2)} = \frac{1}{4}(2 + 3 + 1 + 3, 3 + 2 + 2 + 4) = \left(\frac{9}{4}, \frac{11}{4}\right) = (2.25, 2.75)$$

$$C_2^{(2)} = \frac{1}{4}(4 + 5 + 6 + 6, 5 + 4 + 4 + 5) = \left(\frac{21}{4}, \frac{9}{2}\right) = (5.25, 4.5)$$

Τα κέντρα δεν αλλάξαν, οπότε η κατηγοριοποίηση έχει ολοκληρωθεί.

Αποτέλεσμα:

Τελικές θέσεις κέντρων: $C_1 = (2.25, 2.75)$ και $C_2 = (5.25, 4.5)$

Τελικές κατανομές στις δύο κλάσεις:

Σημεία στην C_1 : $\{(2,3), (3,2), (1,2), (3,4)\}$


Σημεία στην C_2 : $\{(4,5), (5,4), (6,4), (6,5)\}$

Κώδικας προγράμματος

Ερώτημα β

Υλοποιούμε τον αλγόριθμο k – means με τυχαία αρχικοποίηση και τον εφαρμόζουμε στο iris dataset για αριθμό συστάδων $m = 3$ και παράμετρο $\text{tol} = 1e - 5$ που ορίζει ότι ο αλγόριθμος θα τερματίσει όταν η μεταβολή της θέσης των κέντρων είναι μικρότερη από 10^{-5} .

Το confusion matrix και το success rate του αλγόριθμου προέκυψαν ως εξής:



Αρχικά, παρατηρούμε ότι όλα τα 50 δείγματα της κατηγορίας Iris-setosa ταξινομήθηκαν σωστά, γεγονός που δείχνει ότι η συγκεκριμένη κατηγορία είναι απόλυτα διαχωρίσιμη από τις άλλες.

Επιπλέον, από τα 50 δείγματα της κατηγορίας Iris-versicolor, τα 48 ταξινομήθηκαν σωστά, ενώ 2 δείγματα ταξινομήθηκαν εσφαλμένα ως Iris-virginica. Αυτό δείχνει ότι υπάρχει κάποια επικαλυπτόμενη πληροφορία στα χαρακτηριστικά των δύο κατηγοριών που οδηγεί σε μικρά σφάλματα.


Τέλος, από τα 50 δείγματα της κατηγορίας Iris-virginica, τα 36 ταξινομήθηκαν σωστά, ενώ 14 δείγματα ταξινομήθηκαν εσφαλμένα ως Iris-versicolor. Αυτό δείχνει ότι οι δύο αυτές κατηγορίες είναι πιο κοντινές και δύσκολα διαχωρίσιμες στα χαρακτηριστικά τους.

Το success rate του 89.33% είναι αρκετά υψηλό και δείχνει ότι ο αλγόριθμος k-means με πλήρη χαρακτηριστικά μπορεί να διαχωρίσει τις κατηγορίες με σχετικά καλή ακρίβεια.

Ερώτημα γ

Επαναλάβετε την παραπάνω διαδικασία για την περίπτωση που το διάνυσμα χαρακτηριστικών περιλαμβάνει μόνο δύο χαρακτηριστικά, το 'μήκος πετάλων' και το 'πλάτος πετάλων'.

Το confusion matrix και το success rate του αλγόριθμου προέκυψαν ως εξής:




Αρχικά, παρατηρούμε ότι όλα τα 50 δείγματα της κατηγορίας Iris-setosa ταξινομήθηκαν σωστά, γεγονός που δείχνει ότι η συγκεκριμένη κατηγορία είναι απόλυτα διαχωρίσιμη από τις άλλες.

Επιπλέον, από τα 50 δείγματα της κατηγορίας Iris-versicolor, τα 48 ταξινομήθηκαν σωστά, ενώ 2 δείγματα ταξινομήθηκαν εσφαλμένα ως Iris-virginica. Αυτό δείχνει ότι υπάρχει κάποια επικαλυπτόμενη πληροφορία στα χαρακτηριστικά των δύο κατηγοριών που οδηγεί σε μικρά σφάλματα.

Τέλος, από τα 50 δείγματα της κατηγορίας Iris-virginica, τα 44 ταξινομήθηκαν σωστά, ενώ 6 δείγματα ταξινομήθηκαν εσφαλμένα ως Iris-versicolor. Αυτό δείχνει ότι οι δύο αυτές κατηγορίες είναι πιο κοντινές αλλά πιο εύκολα διαχωρίσιμες με βάση τα δύο χαρακτηριστικά, σε σχέση με τα τέσσερα.

Το success rate του 94.67% είναι αρκετά υψηλό και δείχνει ότι ο αλγόριθμος k-means με δύο χαρακτηριστικά μπορεί να διαχωρίσει τις κατηγορίες με σχετικά καλή ακρίβεια.

Επιπλέον, ακολουθεί η γραφική απεικόνιση της παραπάνω ομαδοποίησης και τα κέντρα των κλάσεων που εκτιμά ο αλγόριθμος.



Ερώτημα δ

Η σύγκριση των δύο αποτελεσμάτων δείχνει ότι η κατηγορία *Iris-setosa* ταξινομείται απόλυτα σωστά και στις δύο περιπτώσεις, αποδεικνύοντας ότι είναι πλήρως διαχωρίσιμη. Για την *Iris-versicolor*, 48 από τα 50 δείγματα ταξινομήθηκαν σωστά και στις δύο περιπτώσεις, υποδεικνύοντας μικρή επικαλυπτόμενη πληροφορία με την *Iris-virginica*. Ωστόσο, για την *Iris-virginica*, η ακρίβεια βελτιώνεται από 36/50 σωστές ταξινομήσεις με όλα τα χαρακτηριστικά σε 44/50 σωστές ταξινομήσεις με δύο χαρακτηριστικά (μήκος και πλάτος πετάλων), κάτι που δείχνει καλύτερο διαχωρισμό των κατηγοριών με τα συγκεκριμένα χαρακτηριστικά.

Το συνολικό ποσοστό επιτυχίας αυξάνεται από 89.33% σε 94.67% όταν χρησιμοποιούνται μόνο δύο χαρακτηριστικά, υποδεικνύοντας ότι αυτά είναι πιο διακριτά για την ομαδοποίηση. Η ανάλυση καταδεικνύει ότι η επιλογή χαρακτηριστικών επηρεάζει σημαντικά την απόδοση του αλγορίθμου k-means, με τη χρήση των δύο χαρακτηριστικών να προσφέρει καλύτερη διαχωριστική ικανότητα στο συγκεκριμένο πρόβλημα.

Άσκηση 2.3 (Ιεραρχική Ομαδοποίηση)

Κώδικας προγράμματος

Ερώτημα α

Έστω δύο διανύσματα $x, y \in \mathbb{R}^1$, και θ_{xy} η μεταξύ τους γωνία.

Ορίζουμε την συνάρτηση εγγύτητας $d_c(x, y)$ ως εξής: $d_c(x, y) = 1 - \cos\theta_{xy}$.

Το συνημίτονο $\cos\theta_{xy}$ μπορεί να υπολογιστεί ως εξής: $\cos\theta_{xy} = \frac{x^T y}{\|x\| \|y\|}$.

Η $d_c(x, y)$ έχει τις εξής ιδιότητες:

$$\alpha. -1 \leq \cos\theta_{xy} \leq 1 \Rightarrow 0 \leq 1 - \cos\theta_{xy} \leq 2 \Rightarrow 0 \leq d_c(x, y) \leq 2 \Rightarrow$$

$$\exists d_0 = 0 \in \mathbb{R}: -\infty < 0 \leq d_c(x, y) < \infty \forall x, y \in \mathbb{R}^1$$

$$\beta. d_c(x, x) = 1 - \cos\theta_{xx} = 1 - \cos(0) = 0 \Rightarrow d_c(x, x) = d_0, \forall x \in R^1$$

$$\gamma. \cos\theta_{xy} = \cos\theta_{yx} \Rightarrow 1 - \cos\theta_{xy} = 1 - \cos\theta_{yx} \Rightarrow d_c(x, y) = d_c(y, x) \Rightarrow d_c(x, y) = d_c(y, x), \forall x, y \in R^1$$

Συνεπώς, η $d_c(x, y)$ είναι μέτρο ανομοιότητας (dissimilarity measure).

Επιπλέον, παρατηρούμε ότι για $y = \lambda x$ έχουμε ότι:

$$d_c(x, y) = d_c(x, \lambda x) = 1 - \cos\theta_{x\lambda x} = 1 - \cos(0) = 0 \Rightarrow \exists y \neq x: d_c(x, y) = d_0$$

Συνεπώς, η $d_c(x, y)$ δεν είναι μετρική ανομοιότητας.

Ερώτημα β

Έχουμε το εξής σύνολο προτύπων στο R^2 :

$$X = \{(1, 5), (3, 4), (0, 2), (5, 4), (2, 6), (3, 3), (2, 3), (4, 2)\}$$

Ο πίνακας προτύπων $D(X)$, που περιέχει τις Ευκλείδειες αποστάσεις μεταξύ των προτύπων είναι ο εξής:

Initial Distance Matrix (D):								
	P1	P2	P3	P4	P5	P6	P7	P8
P1	0.000	2.236	3.162	4.123	1.414	2.828	2.236	4.243
P2	2.236	0.000	3.606	2.000	2.236	1.000	1.414	2.236
P3	3.162	3.606	0.000	5.385	4.472	3.162	2.236	4.000
P4	4.123	2.000	5.385	0.000	3.606	2.236	3.162	2.236
P5	1.414	2.236	4.472	3.606	0.000	3.162	3.000	4.472
P6	2.828	1.000	3.162	2.236	3.162	0.000	1.000	1.414
P7	2.236	1.414	2.236	3.162	3.000	1.000	0.000	2.236
P8	4.243	2.236	4.000	2.236	4.472	1.414	2.236	0.000

Ο πίνακας εγγύτητας $P(X)$ με βάση την συνάρτηση εγγύτητας $d_c(x, y) = 1 - \cos\theta_{xy}$ είναι ο εξής:

Initial Proximity Matrix (P):								
	P1	P2	P3	P4	P5	P6	P7	P8
P1	-0.000	0.098	0.019	0.234	0.008	0.168	0.075	0.386
P2	0.098	0.000	0.200	0.032	0.051	0.010	0.002	0.106
P3	0.019	0.200	0.000	0.375	0.051	0.293	0.168	0.553
P4	0.234	0.032	0.375	0.000	0.160	0.006	0.047	0.022
P5	0.008	0.051	0.051	0.160	0.000	0.106	0.035	0.293
P6	0.168	0.010	0.293	0.006	0.106	-0.000	0.019	0.051
P7	0.075	0.002	0.168	0.047	0.035	0.019	-0.000	0.132
P8	0.386	0.106	0.553	0.022	0.293	0.051	0.132	0.000

Ερώτημα γ

Ιεραρχική Ομαδοποίηση με Απλό Δεσμό (Single Linkage)

Αρχικοποίηση:

Κάθε σημείο αποτελεί το δικό του cluster. Υπάρχουν $N = 8$ αρχικά clusters.

Εντοπισμός Εγγύτερων Clusters:

Σε κάθε βήμα, υπολογίζουμε την ελάχιστη απόσταση μεταξύ δύο clusters C_i, C_j :

$$d(C_i, C_j) = \min \{ d(x, y) : x \in C_i, y \in C_j \}$$

Εντοπίζουμε τα clusters που έχουν τη μικρότερη απόσταση και τα συγχωνεύουμε.

Συγχώνευση Clusters:

Τα δύο clusters συγχωνεύονται σε ένα νέο cluster.

Ο πίνακας εγγύτητας ενημερώνεται ώστε να περιλαμβάνει τις αποστάσεις του νέου cluster από τα υπόλοιπα.

Επανάληψη:

Η διαδικασία επαναλαμβάνεται μέχρι να προκύψει ένα ενιαίο cluster που περιλαμβάνει όλα τα δεδομένα.

Οι διαδοχικές ομαδοποιήσεις έγιναν ως εξής:

```
--- Single Linkage Clustering ---

Step 1: Merged clusters 1 and 6 with distance 0.0020
Current clusters: {0: [0], 1: [1, 6], 2: [2], 3: [3], 4: [4], 5: [5], 7: [7]}

Step 2: Merged clusters 3 and 5 with distance 0.0060
Current clusters: {0: [0], 1: [1, 6], 2: [2], 3: [3, 5], 4: [4], 7: [7]}

Step 3: Merged clusters 0 and 4 with distance 0.0080
Current clusters: {0: [0, 4], 1: [1, 6], 2: [2], 3: [3, 5], 7: [7]}


Step 4: Merged clusters 1 and 3 with distance 0.0100
Current clusters: {0: [0, 4], 1: [1, 6, 3, 5], 2: [2], 7: [7]}

Step 5: Merged clusters 0 and 2 with distance 0.0190
Current clusters: {0: [0, 4, 2], 1: [1, 6, 3, 5], 7: [7]}

Step 6: Merged clusters 1 and 7 with distance 0.0220
Current clusters: {0: [0, 4, 2], 1: [1, 6, 3, 5, 7]}

Step 7: Merged clusters 0 and 1 with distance 0.0350
Current clusters: {0: [0, 4, 2, 1, 6, 3, 5, 7]}
```

Το αντίστοιχο δενδρόγραμμα εγγύτητας είναι το εξής:



Ερώτημα δ

Ιεραρχική Ομαδοποίηση με Απλό Δεσμό (Single Linkage)

1. Αρχικοποίηση:

Κάθε σημείο αποτελεί το δικό του cluster. Υπάρχουν $N = 8$ αρχικά clusters.

2. Εντοπισμός Εγγύτερων Clusters:

Σε κάθε βήμα, υπολογίζουμε την μέγιστη απόσταση μεταξύ δύο clusters C_i, C_j :

$$d(C_i, C_j) = \max \{ d(x, y) : x \in C_i, y \in C_j \}$$

Εντοπίζουμε τα clusters που έχουν τη μέγιστη απόσταση και τα συγχωνεύουμε.

3. Συγχώνευση Clusters:

Τα δύο clusters συγχωνεύονται σε ένα νέο cluster.

Ο πίνακας εγγύτητας ενημερώνεται ώστε να περιλαμβάνει τις αποστάσεις του νέου cluster από τα υπόλοιπα.

4. Επανάληψη:

Η διαδικασία επαναλαμβάνεται μέχρι να προκύψει ένα ενιαίο cluster που περιλαμβάνει όλα τα δεδομένα.

Οι διαδοχικές ομαδοποιήσεις έγιναν ως εξής:

--- Complete Linkage Clustering ---

```
Step 1: Merged clusters 1 and 6 with distance 0.0020
Current clusters: {0: [0], 1: [1, 6], 2: [2], 3: [3], 4: [4], 5: [5], 7: [7]}

Step 2: Merged clusters 3 and 5 with distance 0.0060
Current clusters: {0: [0], 1: [1, 6], 2: [2], 3: [3, 5], 4: [4], 7: [7]}

Step 3: Merged clusters 0 and 4 with distance 0.0080
Current clusters: {0: [0, 4], 1: [1, 6], 2: [2], 3: [3, 5], 7: [7]}


Step 4: Merged clusters 1 and 3 with distance 0.0470
Current clusters: {0: [0, 4], 1: [1, 6, 3, 5], 2: [2], 7: [7]}

Step 5: Merged clusters 0 and 2 with distance 0.0510
Current clusters: {0: [0, 4, 2], 1: [1, 6, 3, 5], 7: [7]}

Step 6: Merged clusters 1 and 7 with distance 0.1320
Current clusters: {0: [0, 4, 2], 1: [1, 6, 3, 5, 7]}

Step 7: Merged clusters 0 and 1 with distance 0.5530
Current clusters: {0: [0, 4, 2, 1, 6, 3, 5, 7]}
```

Το αντίστοιχο δενδρόγραμμα εγγύτητας είναι το εξής:



Ερώτημα ε

Η σύγκριση των δύο μεθόδων ομαδοποίησης δείχνει ότι ο απλός δεσμός (Single Linkage) τείνει να δημιουργεί "αλυσίδες" συνδέοντας σημεία με τη μικρότερη απόσταση, γεγονός που τον καθιστά ευαίσθητο σε θόρυβο και outliers. Είναι κατάλληλος για αναλύσεις που επικεντρώνονται σε μικρές αποστάσεις ή σύνδεση, αλλά συχνά οι ομάδες δεν είναι καλά διαχωρισμένες.

Από την άλλη, ο πλήρης δεσμός (Complete Linkage) παράγει πιο συμπαγή και σαφώς διαχωρισμένα clusters, καθώς βασίζεται στη μέγιστη απόσταση μεταξύ σημείων. Αυτή η μέθοδος είναι πιο ανθεκτική σε θόρυβο και προτιμάται σε εφαρμογές που απαιτούν καλά διαχωρισμένες ομάδες.

Και με τις δύο μεθόδους καταλήγουμε σε δύο clusters:

cluster 1: $\{x_1, x_3, x_5\}$

cluster 2: $\{x_2, x_4, x_6, x_7, x_8\}$

Άσκηση 2.4 (Θεωρία PCA)

Έστω μια ακολουθία δεδομένων (τυχαία διανύσματα με μηδενικό μέσο) $x_n \in R^l, n = 1, \dots, N$, με δειγματικό πίνακα συνδιασποράς (sample covariance matrix): $\hat{\Sigma} = \frac{1}{N} \sum_{n=1}^N x_n x_n^T$

Μεταξύ των γραμμικών υπόχωρων διάστασης $m \leq l$, θέλουμε να βρούμε εκείνον στον οποίο η μεταβλητότητα (διασπορά) των προβολών των δεδομένων μεγιστοποιείται. Ο υπόχωρος ορίζεται με βάση m αμοιβαία ορθογώνια μοναδιαία διανύσματα $u_i, i = 1, \dots, m$ που αντιστοιχούν σε m άξονες ή κατευθύνσεις.

Ερώτημα α

Για $m = 1$, θα δείξουμε ότι το διάνυσμα u_1 που καθορίζει τον βέλτιστο μονοδιάστατο υπόχωρο είναι το ίδιο διάνυσμα που αντιστοιχεί στη μεγαλύτερη ιδιοτιμή λ_1 του $\hat{\Sigma}$.

Αφού η υπακολουθία έχει μηδενικό μέσο όρο ισχύει ότι: $\bar{x} = \frac{1}{N} \sum_{n=1}^N x_n = 0$

Η προβολή κάθε δεδομένου x_n πάνω στο διάνυσμα u είναι: $u^T x_n$.

Η διασπορά της προβολής είναι:

$$\begin{aligned} \text{Var}(u^T x_n) &= \frac{1}{N} \sum_{n=1}^N (u^T x_n - u^T \bar{x})^2 = \frac{1}{N} \sum_{n=1}^N (u^T x_n)^2 = u^T \left(\frac{1}{N} \sum_{n=1}^N x_n x_n^T \right) u = u^T \hat{\Sigma} u \Rightarrow \\ \text{Var}(u^T x_n) &= u^T \hat{\Sigma} u \end{aligned}$$

Θέλουμε να μεγιστοποιήσουμε την παραπάνω διασπορά, υπό τον περιορισμό ότι το u είναι μοναδιαίο. Δηλαδή: $\max_{u, \|u\|=1} u^T \hat{\Sigma} u$

Ορίζουμε τη συνάρτηση Lagrange με πολλαπλασιαστή Lagrange λ για τον περιορισμό του μοναδιαίου διανύσματος:

$$\mathcal{L}(u, \lambda) = u^T \hat{\Sigma} u - \lambda(u^T u - 1)$$

Βρίσκουμε το σημείο που μηδενίζεται η παράγωγος ως προς u :

$$\frac{\partial \mathcal{L}(u, \lambda)}{\partial u} = 0 \Rightarrow 2\hat{\Sigma}u - 2\lambda u = 0 \Rightarrow \hat{\Sigma}u = \lambda u$$

Βρίσκουμε το σημείο που μηδενίζεται η παράγωγος ως προς λ :

$$\frac{\partial \mathcal{L}(u, \lambda)}{\partial \lambda} = 0 \Rightarrow -(u^T u - 1) = 0 \Rightarrow u^T u = 1$$

Έτσι, τα διανύσματα u που μεγιστοποιούν την διασπορά είναι ιδιοδιανύσματα του $\hat{\Sigma}$ και η διασπορά που προκύπτει είναι ίση με την αντίστοιχη ιδιοτιμή λ :

$$\text{Var}(u^T x_n) = u^T \hat{\Sigma} u = \lambda$$

Επιπλέον, η συνθήκη $u^T u = 1$ εξασφαλίζει ότι το u είναι μοναδιαίο.

Συνεπώς, το διάνυσμα u_1 που μεγιστοποιεί τη διασπορά των προβολών των δεδομένων στον μονοδιάστατο υπόχωρο είναι το ιδιοδιάνυσμα του $\hat{\Sigma}$ που αντιστοιχεί στη μεγαλύτερη ιδιοτιμή λ_1 και η διασπορά της προβολής στον υπόχωρο αυτόν είναι ίση με λ_1 .

Ερώτημα β

Για $m = 2$, θα δείξουμε ότι τα διανύσματα u_1, u_2 που καθορίζουν τον βέλτιστο διδιάστατο υπόχωρο είναι τα ιδιοδιανύσματα που αντιστοιχούν στις δύο μεγαλύτερες ιδιοτιμές λ_1, λ_2 του $\hat{\Sigma}$.

Αφού η υπακολουθία έχει μηδενικό μέσο όρο ισχύει ότι: $\bar{x} = \frac{1}{N} \sum_{n=1}^N x_n = 0$

Η προβολή κάθε δεδομένου x_n πάνω στον διδιάστατο υπόχωρο που ορίζεται από τα διανύσματα u_1, u_2 είναι $U^T x_n$, όπου $U = [u_1 \ u_2] \in \mathbb{R}^{l \times 2}$

Η διασπορά της προβολής πάνω στα u_1, u_2 είναι το άθροισμα:

$$\text{Var}(U^T x_n) = \text{Var}(u_1^T x_n) + \text{Var}(u_2^T x_n) = u_1^T \hat{\Sigma} u_1 + u_2^T \hat{\Sigma} u_2$$

Θέλουμε να μεγιστοποιήσουμε τη συνολική διασπορά, υπό τους περιορισμούς ότι u_1, u_2 είναι μοναδιαία και κάθετα μεταξύ τους. Δηλαδή:

$$\max_{u_1, u_2: \|u_1\|=\|u_2\|=1, u_1 \perp u_2} (u_1^T \hat{\Sigma} u_1 + u_2^T \hat{\Sigma} u_2)$$

Ορίζουμε τη συνάρτηση Lagrange με πολλαπλασιαστές Lagrange λ_1, λ_2 για τον περιορισμό των μοναδιαίων διανυσμάτων και πολλαπλασιαστή γ για τον περιορισμό της ορθογωνιότητας:

$$\mathcal{L}(u_1, u_2, \lambda_1, \lambda_2, \gamma) = u_1^T \hat{\Sigma} u_1 + u_2^T \hat{\Sigma} u_2 - \lambda_1 (u_1^T u_1 - 1) - \lambda_2 (u_2^T u_2 - 1) - \gamma u_1^T u_2$$

Βρίσκουμε το σημείο που μηδενίζεται η παράγωγος ως προς u_1 :

$$\frac{\partial \mathcal{L}}{\partial u_1} = 0 \Rightarrow 2\hat{\Sigma} u_1 - 2\lambda_1 u_1 - \gamma u_2 = 0 \Rightarrow \hat{\Sigma} u_1 = \lambda_1 u_1 + \frac{\gamma}{2} u_2$$

Βρίσκουμε το σημείο που μηδενίζεται η παράγωγος ως προς u_2 :

$$\frac{\partial \mathcal{L}}{\partial u_2} = 0 \Rightarrow 2\hat{\Sigma} u_2 - 2\lambda_2 u_2 - \gamma u_1 = 0 \Rightarrow \hat{\Sigma} u_2 = \lambda_2 u_2 + \frac{\gamma}{2} u_1$$

Βρίσκουμε το σημείο που μηδενίζεται η παράγωγος ως προς λ_1 :

$$\frac{\partial \mathcal{L}}{\partial \lambda_1} = 0 \Rightarrow -(u_1^T u_1 - 1) = 0 \Rightarrow u_1^T u_1 = 1$$

Βρίσκουμε το σημείο που μηδενίζεται η παράγωγος ως προς λ_2 :

$$\frac{\partial \mathcal{L}}{\partial \lambda_2} = 0 \Rightarrow -(u_2^T u_2 - 1) = 0 \Rightarrow u_2^T u_2 = 1$$

Βρίσκουμε το σημείο που μηδενίζεται η παράγωγος ως προς γ :

$$\frac{\partial \mathcal{L}}{\partial \gamma} = 0 \Rightarrow -u_1^T u_2 = 0 \Rightarrow u_1^T u_2 = 0$$

Έτσι, τα διανύσματα u_1, u_2 που μεγιστοποιούν την διασπορά είναι ιδιοδιανύσματα του $\hat{\Sigma}$ και η διασπορά που προκύπτει είναι ίση με το άθροισμα των αντίστοιχων ιδιοτιμών λ_1, λ_2 :

$$\text{Var}(U^T x_n) = u_1^T \hat{\Sigma} u_1 + u_2^T \hat{\Sigma} u_2 = \lambda_1 + \lambda_2$$

Επιπλέον, οι συνθήκες $u_1^T u_1 = 1$ και $u_2^T u_2 = 1$ εξασφαλίζουν ότι τα διανύσματα είναι μοναδιαία και η συνθήκη $u_1^T u_2 = 0$ εξασφαλίζει την ορθογωνιότητα.

Συνεπώς, τα διάνυσμα u_1, u_2 που μεγιστοποιούν τη διασπορά των προβολών των δεδομένων στον δισδιάστατο υπόχωρο είναι τα ιδιοδιανύσματα του $\hat{\Sigma}$ που αντιστοιχούν στις μεγαλύτερες ιδιοτιμές λ_1, λ_2 και η συνολική διασπορά είναι ίση με $\lambda_1 + \lambda_2$.

Ερώτημα γ

Για $m \geq 1$, θα δείξουμε ότι τα διανύσματα $u_1, \dots, u_m$ που καθορίζουν τον βέλτιστο m -διάστατο υπόχωρο είναι τα ιδιοδιανύσματα που αντιστοιχούν στις m μεγαλύτερες ιδιοτιμές $\lambda_1, \dots, \lambda_m$ του $\hat{\Sigma}$.

Αφού η υπακολουθία έχει μηδενικό μέσο όρο ισχύει ότι: $\bar{x} = \frac{1}{N} \sum_{n=1}^N x_n = 0$

Η προβολή κάθε δεδομένου x_n πάνω στον m -διάστατο υπόχωρο που ορίζεται από τα διανύσματα $u_1, \dots, u_m$ είναι $U^T x_n$, όπου $U = [u_1 \dots u_m] \in \mathbb{R}^{l \times m}$

Η διασπορά της προβολής πάνω στα u_1, u_2 είναι το άθροισμα:

$$\text{Var}(U^T x_n) = \sum_{i=1}^m \text{Var}(u_i^T x_n) = \sum_{i=1}^m u_i^T \hat{\Sigma} u_i$$

Θέλουμε να μεγιστοποιήσουμε τη συνολική διασπορά, υπό τους περιορισμούς ότι $u_1, \dots, u_m$ είναι μοναδιαία και κάθετα ανά δύο μεταξύ τους. Δηλαδή: $\max_{u_1 \dots u_m: \|u_i\|=1, u_i \perp u_j} \sum_{i=1}^m u_i^T \hat{\Sigma} u_i$

Ορίζουμε τη συνάρτηση Lagrange με πολλαπλασιαστές Lagrange $\lambda_1, \dots, \lambda_m$ για τον περιορισμό των μοναδιαίων διανυσμάτων και πολλαπλασιαστή γ_{ij} για τον περιορισμό της ορθογωνιότητας:

$$\mathcal{L}(u_1, \dots, u_m, \lambda_1, \dots, \lambda_m, \gamma_{ij}) = \sum_{i=1}^m u_i^T \hat{\Sigma} u_i - \sum_{i=1}^m \lambda_i (u_i^T u_i - 1) - \sum_{i \neq j} \gamma_{ij} (u_i^T u_j)$$

Βρίσκουμε το σημείο που μηδενίζεται η παράγωγος ως προς u_i :

$$\frac{\partial \mathcal{L}}{\partial u_i} = 0 \Rightarrow 2\hat{\Sigma} u_i - 2\lambda_i u_i - \sum_{i \neq j} \gamma_{ij} u_j = 0 \Rightarrow \hat{\Sigma} u_i = \lambda_i u_i + \frac{1}{2} \sum_{i \neq j} \gamma_{ij} u_j$$

Βρίσκουμε το σημείο που μηδενίζεται η παράγωγος ως προς λ_i :

$$\frac{\partial \mathcal{L}}{\partial \lambda_i} = 0 \Rightarrow -(u_i^T u_i - 1) = 0 \Rightarrow u_i^T u_i = 1, i = 1, \dots, m$$

Βρίσκουμε το σημείο που μηδενίζεται η παράγωγος ως προς γ_{ij} :

$$\frac{\partial \mathcal{L}}{\partial \gamma_{ij}} = 0 \Rightarrow -u_i^T u_j = 0 \Rightarrow u_i^T u_j = 0, i \neq j$$

Έτσι, τα διανύσματα $u_1, \dots, u_m$ που μεγιστοποιούν την διασπορά είναι ιδιοδιανύσματα του $\hat{\Sigma}$ και η διασπορά που προκύπτει είναι ίση με το άθροισμα των αντίστοιχων ιδιοτιμών $\lambda_1, \dots, \lambda_m$: $Var(U^T x_n) = \sum_{i=1}^m u_i^T \hat{\Sigma} u_i = \sum_{i=1}^m \lambda_i$

Επιπλέον, οι συνθήκες $u_i^T u_i = 1$ εξασφαλίζουν ότι τα διανύσματα είναι μοναδιαία και οι συνθήκες $u_i^T u_j = 0$ εξασφαλίζουν την ορθογωνιότητα.

Συνεπώς, τα διανύσματα $u_1, \dots, u_m$ που μεγιστοποιούν τη διασπορά των προβολών των δεδομένων στον m -διάστατο υπόχωρο είναι τα ιδιοδιανύσματα του $\hat{\Sigma}$ που αντιστοιχούν στις μεγαλύτερες ιδιοτιμές $\lambda_1, \dots, \lambda_m$ και η συνολική διασπορά είναι ίση με $\lambda_1 + \dots + \lambda_m$.

Ερώτημα δ

Έστω $x_n \in R^l, n = 1, \dots, N$, τα τυχαία διανύσματα δεδομένων με μηδενικό μέσο όρο. Ο πίνακας συνδιασποράς των δεδομένων ορίζεται ως: $\hat{\Sigma} = \frac{1}{N} \sum_{n=1}^N x_n x_n^T$, είναι συμμετρικός και θετικά ημιορισμένος, επομένως έχει l μη αρνητικές ιδιοτιμές $\lambda_1, \dots, \lambda_m$.

Ισχύει ότι: $trace(\hat{\Sigma}) = trace\left(\frac{1}{N} \sum_{n=1}^N x_n x_n^T\right) = \frac{1}{N} \sum_{n=1}^N trace(x_n x_n^T) = \frac{1}{N} \sum_{n=1}^N \|x_n\|^2$

Επειδή ο πίνακας είναι συμμετρικός ισχύει ότι: $trace(\hat{\Sigma}) = \sum_{i=1}^l \lambda_i$

Η συνολική διασπορά των δεδομένων $\{x_n\}_{n=1}^N$ ορίζεται ως $\sum_{i=1}^l \lambda_i$

Η PCA επιλέγει τις m πρώτες κύριες συνιστώσες που αντιστοιχούν στις m μεγαλύτερες ιδιοτιμές $\lambda_1, \dots, \lambda_m$ για να εξηγήσει τη μέγιστη δυνατή διασπορά των δεδομένων στον m -διάστατο υπόχωρο. Η συνολική διασπορά από αυτές τις συνιστώσες ορίζεται ως $\sum_{i=1}^m \lambda_i$

Το ποσοστό p της διασποράς των δεδομένων που 'ερμηνεύεται' από m κύριες συνιστώσες δίνεται από τη σχέση: $p = \frac{\text{διασπορά από } m \text{ συνιστώσες}}{\text{συνολική διασπορά}} = \frac{\sum_{i=1}^m \lambda_i}{\sum_{i=1}^l \lambda_i} = N \frac{\sum_{i=1}^m \lambda_i}{\sum_{n=1}^N \|x_n\|^2}$

Άσκηση 2.5 (Markov Decision Processes – Reinforcement Learning)

Θεωρούμε ότι ένα ρομπότ κινείται σε ένα πλέγμα 4×4 με ντετερμινιστικές κινήσεις. Το ρομπότ μπορεί να κινηθεί πάνω, κάτω, αριστερά ή δεξιά και λαμβάνει ανταμοιβές ως εξής:

- +10 αν φτάσει στον στόχο (3,3)
- -1 για κάθε κίνηση
- -10 αν καταλήξει στην παγίδα (2,2)

Ερώτημα α

Προκειμένου να προσεγγίσουμε το πρόβλημα με MDP πρέπει να καθορίσουμε τα εξής:

Καταστάσεις S :

Το ρομπότ κινείται σε πλέγμα 4×4 , οπότε υπάρχουν 16 καταστάσεις:

$$S = \{(i, j) | i, j \in \{0, 1, 2, 3\}\}$$

Ειδικές καταστάσεις: στόχος (3,3) και παγίδα (2,2)

Ενέργειες A :

Το ρομπότ μπορεί να κινηθεί ως εξής:

- Πάνω: $(i, j) \rightarrow (i - 1, j), i > 0$
- Κάτω: $(i, j) \rightarrow (i + 1, j), i < 3$
- Δεξιά: $(i, j) \rightarrow (i, j - 1), j > 0$
- Αριστερά: $(i, j) \rightarrow (i, j + 1), j < 3$

Οπότε υπάρχουν 4 ενέργειες: $A = \{Up, Down, Left, Right\}$

Ανταμοιβές $R(s, a, s')$:

Για το ρομπότ υπάρχουν οι εξής αμοιβές:

- +10 αν φτάσει στον στόχο (3,3): $R(s, a, s') = +9, s' = (3,3)$
- -1 για κάθε κίνηση: $R(s, a, s') = -1$
- -10 αν καταλήξει στην παγίδα (2,2): $R(s, a, s') = -11, s' = (2,2)$

Οπότε η συνάρτηση ανταμοιβής είναι: $R(s, a, s') = \begin{cases} +9, s' = (3,3) \\ -11, s' = (2,2) \\ -1, otherwise \end{cases}$

Πιθανότητες μετάβασης $P(s'|s, a)$

Οι μεταβάσεις του ρομπότ είναι ντετερμινιστικές:

- Αν η a είναι έγκυρη: $P(s'|s, a) = 1$
- Αν η a δεν είναι έγκυρη: $P(s'|s, a) = 0$

Οπότε οι πιθανότητες μετάβασης είναι: $P(s'|s, a) = \begin{cases} 1, & a \text{ έγκυρη} \\ 0, & a \text{ μη έγκυρη} \end{cases}$

Ερώτημα β

Η εξίσωση Bellman $V^\pi(s)$ για μία κατάσταση s , υπό την πολιτική π και συντελεστή προεξόφλησης γ υπολογίζεται ως εξής:

$$V^\pi(s) = \sum_{s'} P(s'|s, \pi(s)) [R(s, \pi(s), s') + \gamma V^\pi(s')]$$

Ερώτημα γ

Προκειμένου το ρομπότ να κινηθεί από την αρχική κατάσταση (0,0) στον στόχο (3,3) πρέπει να κάνει 3 κινήσεις Δεξιά και 3 κινήσεις Κάτω.

Οι πρώτες 5 κινήσεις φέρνουν ανταμοιβή $R(s, a, s') = R_i = -1, i = 1, \dots, 5$

Η τελευταία κίνηση φέρει ανταμοιβή $R(s, a, s') = R_6 = +9$

Η τιμή της αρχικής κατάστασης για $\gamma = 0.9$ ορίζεται ως εξής:

$$V^\pi((0,0)) = \sum_{s'} P(s'|s, \pi(s)) [R(s, \pi(s), s') + \gamma V^\pi(s')]$$

$$V^\pi((0,0)) = R(s, \pi(s), s') + \gamma V^\pi(s')$$

$$V^\pi((0,0)) = \sum_{i=0}^5 \gamma^i R_i$$

$$V^\pi((0,0)) = R_0 + \gamma R_1 + \gamma^2 R_2 + \gamma^3 R_3 + \gamma^4 R_4 + \gamma^5 R_5$$

$$V^\pi((0,0)) = -1 + \gamma(-1) + \gamma^2(-1) + \gamma^3(-1) + \gamma^4(-1) + \gamma^5(9)$$

$$V^\pi((0,0)) = -1 + 0.9(-1) + 0.9^2(-1) + 0.9^3(-1) + 0.9^4(-1) + 0.9^5(9)$$

$$V^\pi((0,0)) = 1.21931$$

Ερώτημα δ

Η ύπαρξη της παγίδας (2,2) με την αρνητική ανταμοιβή -11 μειώνει σημαντικά τις τιμές των γειτονικών καταστάσεων, καθώς αυτές σχετίζονται με τον κίνδυνο μετάβασης στην παγίδα. Αυτή η αρνητική επιρροή εξαπλώνεται και σε πιο απομακρυσμένες καταστάσεις μέσω της

εξίσωσης Bellman, αν και με μικρότερη ένταση. Το αποτέλεσμα είναι η δημιουργία μιας ζώνης χαμηλής αξίας γύρω από την παγίδα, που μειώνει την επιθυμητότητα των καταστάσεων κοντά σε αυτήν και αναγκάζει το ρομπότ να προσαρμόσει την πολιτική του για να αποφύγει τη συγκεκριμένη περιοχή.

Κώδικες προγραμμάτων

Άσκηση 2.1 (python code)

```
import pandas as pd
import numpy as np

data = {
    "X1": [1, 1, 0, 0, 1, 1, 0, 1, 0],
    "X2": [1, 1, 0, 1, 0, 0, 1, 1, 0],
    "X3": [0, 0, 1, 1, 0, 1, 0, 1, 0],
    "X4": [0, 1, 0, 1, 0, 1, 1, 1, 1],
    "Y": [1, 1, 1, 1, 1, -1, -1, -1, -1]
}

df = pd.DataFrame(data)

def gini_index(groups, classes):
    # Count all samples
    total_instances = sum([len(group) for group in groups])
    gini = 0.0
    for group in groups:
        size = len(group)
        if size == 0:
            continue
        score = 0.0
        for class_val in classes:
            proportion = (group.count(class_val) / size)
            score += proportion ** 2
        gini += (1.0 - score) * (size / total_instances)
    return gini

def split_data(data, feature):
    unique_values = data[feature].unique()
    groups = []
    for value in unique_values:
```

```

        groups.append(list(data[data[feature] == value]['Y']))
    return groups

def calculate_gini_for_feature(data, feature):
    classes = data['Y'].unique()
    groups = split_data(data, feature)
    return gini_index(groups, classes)

# Root Gini Index
root_gini = gini_index([list(df['Y'])], df['Y'].unique())
print(f"Gini(Root): {root_gini:.4f}")

# Gini for each feature
features = ['X1', 'X2', 'X3', 'X4']
gini_values = {}
for feature in features:
    gini = calculate_gini_for_feature(df, feature)
    gini_values[feature] = gini
    print(f"Gini({feature}): {gini:.4f}")

# Information Gain
info_gains = {}
print("\nInformation Gain:")
for feature in features:
    info_gain = root_gini - gini_values[feature]
    info_gains[feature] = info_gain
    print(f"IG({feature}): {info_gain:.4f}")

# Splitting for X4 (First Level)
X4_0 = df[df['X4'] == 0]
X4_1 = df[df['X4'] == 1]

# Gini for X4 branches
X4_0_gini = gini_index([list(X4_0['Y'])], df['Y'].unique())
X4_1_gini = gini_index([list(X4_1['Y'])], df['Y'].unique())
print(f"\nGini(X4=0): {X4_0_gini:.4f}")
print(f"Gini(X4=1): {X4_1_gini:.4f}")

# For X4=1, further split
features_remaining = ['X1', 'X2', 'X3']

```

```

# Calculate Gini for X1, X2, X3 within X4=1
print("\nGini for branches under X4=1:")
for feature in features_remaining:
    gini = calculate_gini_for_feature(X4_1, feature)
    print(f"Gini(X4=1, {feature}): {gini:.4f}")

# Information Gain for X4=1
print("\nInformation Gain for branches under X4=1:")
for feature in features_remaining:
    info_gain = X4_1_gini - calculate_gini_for_feature(X4_1, feature)
    print(f"IG(X4=1, {feature}): {info_gain:.4f}")

# Split further based on best feature (e.g., X2 if selected)
X4_1_X2_0 = X4_1[X4_1['X2'] == 0]
X4_1_X2_1 = X4_1[X4_1['X2'] == 1]

# Gini for X2 branches under X4=1
X4_1_X2_0_gini = gini_index([list(X4_1_X2_0['Y'])], df['Y'].unique())
X4_1_X2_1_gini = gini_index([list(X4_1_X2_1['Y'])], df['Y'].unique())
print(f"\nGini(X4=1, X2=0): {X4_1_X2_0_gini:.4f}")
print(f"Gini(X4=1, X2=1): {X4_1_X2_1_gini:.4f}")

# Final splits for X4=1, X2=1 (e.g., X1 and X3)
features_final = ['X1', 'X3']

print("\nFinal splits for X4=1, X2=1:")
for feature in features_final:
    gini = calculate_gini_for_feature(X4_1_X2_1, feature)
    print(f"Gini(X4=1, X2=1, {feature}): {gini:.4f}")

```

Άσκηση 2.2α (python code)

```

import numpy as np
import pandas as pd
from sklearn.metrics import confusion_matrix, accuracy_score, ConfusionMatrixDisplay
from sklearn.preprocessing import LabelEncoder
import matplotlib.pyplot as plt

```

```

# Load the dataset
iris_data = pd.read_csv('iris.csv')

# Extract features and true labels
X = iris_data[['SepalLengthCm', 'SepalWidthCm', 'PetalLengthCm', 'PetalWidthCm']].values
y_true = iris_data['Species'].values

# Encode labels as integers for comparison
label_encoder = LabelEncoder()
y_true_encoded = label_encoder.fit_transform(y_true)

# K-means implementation
def kmeans(X, n_clusters, max_iter=300, tol=1e-5, random_state=None):
    if random_state:
        np.random.seed(random_state)

    # Step 1: Initialize centroids randomly
    n_samples, n_features = X.shape
    centroids = X[np.random.choice(n_samples, n_clusters, replace=False)]

    for iteration in range(max_iter):
        # Step 2: Assign clusters
        distances = np.linalg.norm(X[:, np.newaxis] - centroids, axis=2)
        labels = np.argmin(distances, axis=1)

        # Step 3: Update centroids
        new_centroids = np.array([X[labels == k].mean(axis=0) for k in range(n_clusters)])

        # Check for convergence
        if np.linalg.norm(new_centroids - centroids) < tol:
            break

        centroids = new_centroids

    return labels, centroids

# Apply custom k-means
n_clusters = 3
y_pred, centroids = kmeans(X, n_clusters, max_iter=300, tol=1e-5, random_state=42)

```

```

# Map predicted clusters to true species
mapping = {}
for cluster in range(n_clusters):
    mask = (y_pred == cluster)
    majority_label = np.bincount(y_true_encoded[mask]).argmax()
    mapping[cluster] = majority_label

# Remap predicted labels
y_pred_mapped = np.vectorize(mapping.get)(y_pred)

# Compute confusion matrix and success rate
conf_matrix = confusion_matrix(y_true_encoded, y_pred_mapped)
success_rate = accuracy_score(y_true_encoded, y_pred_mapped)

# Print results
print("Confusion Matrix (All features):")
print(conf_matrix)
print(f"Success Rate: {success_rate * 100:.2f}%")

# Plot confusion matrix
plt.figure(figsize=(6, 5))
disp = ConfusionMatrixDisplay(confusion_matrix=conf_matrix, display_labels=label_encoder.classes_)
disp.plot(cmap=plt.cm.Blues, ax=plt.gca())
plt.title("Confusion Matrix (All features)")
plt.show()

```

Άσκηση 2.2β (python code)

```

import numpy as np
import pandas as pd

from sklearn.metrics import confusion_matrix, accuracy_score, ConfusionMatrixDisplay
from sklearn.preprocessing import LabelEncoder
import matplotlib.pyplot as plt

# Load the dataset
iris_data = pd.read_csv('iris.csv')

# Extract features and true labels
X = iris_data[['SepalLengthCm', 'SepalWidthCm', 'PetalLengthCm', 'PetalWidthCm']].values

```

```

y_true = iris_data["Species"].values

# Encode labels as integers for comparison
label_encoder = LabelEncoder()
y_true_encoded = label_encoder.fit_transform(y_true)

# K-means implementation
def kmeans(X, n_clusters, max_iter=300, tol=1e-5, random_state=None):
    if random_state:
        np.random.seed(random_state)

    # Step 1: Initialize centroids randomly
    n_samples, n_features = X.shape
    centroids = X[np.random.choice(n_samples, n_clusters, replace=False)]

    for iteration in range(max_iter):
        # Step 2: Assign clusters
        distances = np.linalg.norm(X[:, np.newaxis] - centroids, axis=2)
        labels = np.argmin(distances, axis=1)

        # Step 3: Update centroids
        new_centroids = np.array([X[labels == k].mean(axis=0) for k in range(n_clusters)])

        # Check for convergence
        if np.linalg.norm(new_centroids - centroids) < tol:
            break

        centroids = new_centroids

    return labels, centroids

# Apply custom k-means
n_clusters = 3
y_pred, centroids = kmeans(X, n_clusters, max_iter=300, tol=1e-5, random_state=42)

# Map predicted clusters to true species
mapping = {}
for cluster in range(n_clusters):
    mask = (y_pred == cluster)
    majority_label = np.bincount(y_true_encoded[mask]).argmax()

```

```

mapping[cluster] = majority_label

# Remap predicted labels
y_pred_mapped = np.vectorize(mapping.get)(y_pred)

# Compute confusion matrix and success rate
conf_matrix = confusion_matrix(y_true_encoded, y_pred_mapped)
success_rate = accuracy_score(y_true_encoded, y_pred_mapped)

# Print results
print("Confusion Matrix (All features):")
print(conf_matrix)
print(f"Success Rate: {success_rate * 100:.2f}%")

# Plot confusion matrix
plt.figure(figsize=(6, 5))
disp = ConfusionMatrixDisplay(confusion_matrix=conf_matrix, display_labels=label_encoder.classes_)
disp.plot(cmap=plt.cm.Blues, ax=plt.gca())
plt.title("Confusion Matrix (All features)")
plt.show()

```

Άσκηση 2.3 (python code)

```

import numpy as np
import pandas as pd
import scipy.cluster.hierarchy as sch
import matplotlib.pyplot as plt

# Data: Set of patterns in R^2
X = np.array([(1, 5), (3, 4), (0, 2), (5, 4), (2, 6), (3, 3), (2, 3), (4, 2)])

# Calculate the distance matrix D(X) using Euclidean distance
def calculate_distance_matrix(X):
    num_points = len(X)
    D = np.zeros((num_points, num_points))
    for i in range(num_points):
        for j in range(num_points):
            D[i, j] = np.linalg.norm(X[i] - X[j])
    return np.round(D, 3)

```

```

# Calculate the proximity matrix P(X) based on the metric  $d_c = 1 - \cos(\theta_{xy})$ 
def calculate_proximity_matrix(X):
    num_points = len(X)
    P = np.zeros((num_points, num_points))
    for i in range(num_points):
        for j in range(num_points):
            dot_product = np.dot(X[i], X[j])
            norm_i = np.linalg.norm(X[i])
            norm_j = np.linalg.norm(X[j])
            cos_theta = dot_product / (norm_i * norm_j)
            P[i, j] = 1 - cos_theta
    return np.round(P, 3)

# Hierarchical clustering using Single Linkage
def single_linkage_clustering(P):
    num_points = P.shape[0]
    clusters = {i: [i] for i in range(num_points)} # Initialize each point as its own cluster
    steps = []

    while len(clusters) > 1:
        # Find the pair of clusters with the smallest minimum distance
        smallest_min_distance = np.inf
        to_merge = None

        for c1 in clusters:
            for c2 in clusters:
                if c1 != c2:
                    distances = [P[i, j] for i in clusters[c1] for j in clusters[c2]]
                    min_dist = min(distances)
                    if min_dist < smallest_min_distance:
                        smallest_min_distance = min_dist
                        to_merge = (c1, c2)

        # Merge the two closest clusters
        c1, c2 = to_merge
        clusters[c1].extend(clusters[c2])
        del clusters[c2]

    # Update the proximity matrix for the new cluster

```

```

    for other in clusters:
        if other != c1:
            distances = [P[i, j] for i in clusters[c1] for j in clusters[other]]
            P[c1, other] = P[other, c1] = min(distances)

    # Record the step
    steps.append((c1, c2, smallest_min_distance))

    # Print the current state of clusters
    print(f"Step {len(steps)}: Merged clusters {c1} and {c2} with distance {smallest_min_distance:.4f}")
    print(f"Current clusters: {clusters}\n")

    return steps

# Hierarchical clustering using Complete Linkage
def complete_linkage_clustering(P):
    num_points = P.shape[0]
    clusters = {i: [i] for i in range(num_points)} # Initialize each point as its own cluster
    steps = []

    while len(clusters) > 1:
        # Find the pair of clusters with the smallest maximum distance
        smallest_max_distance = np.inf
        to_merge = None

        for c1 in clusters:
            for c2 in clusters:
                if c1 != c2:
                    distances = [P[i, j] for i in clusters[c1] for j in clusters[c2]]
                    max_dist = max(distances)
                    if max_dist < smallest_max_distance:
                        smallest_max_distance = max_dist
                        to_merge = (c1, c2)

        # Merge the two closest clusters
        c1, c2 = to_merge
        clusters[c1].extend(clusters[c2])
        del clusters[c2]

    # Update the proximity matrix for the new cluster

```

```

    for other in clusters:
        if other != c1:
            distances = [P[i, j] for i in clusters[c1] for j in clusters[other]]
            P[c1, other] = P[other, c1] = max(distances)

    # Record the step
    steps.append((c1, c2, smallest_max_distance))

    # Print the current state of clusters
    print(f"Step {len(steps)}: Merged clusters {c1} and {c2} with distance {smallest_max_distance:.4f}")
    print(f"Current clusters: {clusters}\n")

    return steps

# Main execution
D = calculate_distance_matrix(X)
print("\nInitial Distance Matrix (D):")
print(pd.DataFrame(D, columns=[f"P{j+1}" for j in range(len(X))], index=[f"P{i+1}" for i in range(len(X))]))

P = calculate_proximity_matrix(X)
print("\nInitial Proximity Matrix (P):")
print(pd.DataFrame(P, columns=[f"P{j+1}" for j in range(len(X))], index=[f"P{i+1}" for i in range(len(X))]))

print("\n--- Single Linkage Clustering ---\n")
single_linkage_steps = single_linkage_clustering(P.copy())

# Plot the dendrogram for single linkage
condensed_P_single = sch.distance.squareform(P, checks=False)
linkage_matrix_single = sch.linkage(condensed_P_single, method='single')
plt.figure(figsize=(10, 6))
sch.dendrogram(linkage_matrix_single, labels=[f"P{i+1}" for i in range(len(X))])
plt.title("Dendrogram of Hierarchical Clustering (Single Linkage)")
plt.xlabel("Patterns")
plt.ylabel("Proximity (1 - Cosθ)")
plt.show()

print("\n--- Complete Linkage Clustering ---\n")
complete_linkage_steps = complete_linkage_clustering(P.copy())

# Plot the dendrogram for complete linkage

```

```
condensed_P_complete = sch.distance.squareform(P, checks=False)
linkage_matrix_complete = sch.linkage(condensed_P_complete, method='complete')
plt.figure(figsize=(10, 6))
sch.dendrogram(linkage_matrix_complete, labels=[f"P{i+1}" for i in range(len(X))])
plt.title("Dendrogram of Hierarchical Clustering (Complete Linkage)")
plt.xlabel("Patterns")
plt.ylabel("Proximity (1 - Cosθ)")
plt.show()
```